

ỦY BAN NHÂN DÂN THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC SÀI GÒN

KHOA CÔNG NGHỆ THÔNG TIN

NGUYỄN VĂN AN

TRƯƠNG GIA Hào

THUẬT TOÁN PSO GIẢI BÀI TOÁN DỰ ĐOÁN GIÁ
VÀNG DỰA VÀO DỮ LIỆU THỜI GIAN THỰC

ĐỒ ÁN CHUYÊN NGÀNH

NGÀNH: CÔNG NGHỆ THÔNG TIN

Thành phố Hồ Chí Minh, năm 2026

ỦY BAN NHÂN DÂN THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC SÀI GÒN

KHOA CÔNG NGHỆ THÔNG TIN

NGUYỄN VĂN AN

TRƯƠNG GIA HÀO

THUẬT TOÁN PSO GIẢI BÀI TOÁN DỰ ĐOÁN GIÁ
VÀNG DỰA VÀO DỮ LIỆU THỜI GIAN THỰC

ĐỒ ÁN CHUYÊN NGÀNH

NGÀNH: CÔNG NGHỆ THÔNG TIN

GIẢNG VIÊN HƯỚNG DẪN: TS. Phan Tấn Quốc

Thành phố Hồ Chí Minh, năm 2026

LỜI CAM ĐOAN

Chúng tôi gồm: Nguyễn Văn An và Trương Gia Hào, xin cam đoan rằng kết quả nghiên cứu được trình bày trong Đồ án chuyên ngành (ĐACN) này là công trình nghiên cứu của nhóm chúng tôi dưới sự hướng dẫn của Giảng viên Nguyễn Tấn Quốc. Các kết quả nghiên cứu của các tác giả khác và các số liệu được sử dụng trong ĐACN đều có trích dẫn đầy đủ và rõ ràng. Kết quả nghiên cứu chung được trình bày trong ĐACN đều có sự đồng ý của các đồng tác giả.

Tác giả

Nguyễn Văn An

Trương Gia Hào

LỜI CẢM ƠN

Lời cảm ơn đầu tiên xin được gửi đến ba mẹ, bạn bè, những người đã luôn bên cạnh động viên và tin tưởng ở chúng tôi.

Xin gửi lời cảm ơn đến tất cả thầy cô, giảng viên của khoa công nghệ thông tin trường Đại học Sài Gòn vì những kiến thức mà các giảng viên trong trường đã giảng dạy suốt bốn năm qua đã làm nền tảng cơ bản cho chúng tôi hoàn thành đồ án chuyên ngành này.

Cuối cùng, xin cảm ơn sâu sắc đối với Tiến sĩ Phan Tấn Quốc người thầy đáng kính đã đóng vai trò hướng dẫn, chỉ lối cho chúng tôi trong suốt những tháng qua để chúng tôi có thể hoàn thành công trình nghiên cứu của mình

DANH MỤC CÁC KÝ HIỆU, CÁC CHỮ VIẾT TẮT

Từ viết tắt	Từ tiếng Anh	Diễn giải/Tạm dịch
ANN	Artificial Neural Network	Mạng nơ-ron nhân tạo
ARCH/GARCH	Autoregressive Conditional Heteroskedasticity / Generalized ARCH	Mô hình phương sai thay đổi có điều kiện
ARIMA	Autoregressive Integrated Moving Average	Mô hình tự hồi quy tích hợp trung bình trượt
ARIMAX	Autoregressive Integrated Moving Average with Exogenous Inputs	Mô hình ARIMA tích hợp các biến ngoại sinh
Bi-GRU	Bidirectional Gated Recurrent Unit	Mạng GRU hai chiều
Bi-LSTM	Bidirectional Long Short-Term Memory	Mạng LSTM hai chiều
CNN	Convolutional Neural Network	Mạng nơ-ron tích chập
FA	Firefly Algorithm	Thuật toán đom đóm
GPP	Gold Price Prediction	Dự đoán giá vàng
GRU	Gated Recurrent Unit	Đơn vị hồi quy có cổng

KNN	K-Nearest Neighbors	Thuật toán K láng giềng gần nhất
LSTM	Long Short-Term Memory	Mạng bộ nhớ ngắn - dài hạn
MAE	Mean Absolute Error	Sai số tuyệt đối trung bình
MAPE	Mean Absolute Percentage Error	Sai số phần trăm tuyệt đối trung bình
MSE	Mean Squared Error	Sai số bình phương trung bình
PSO	Particle Swarm Optimization	Thuật toán tối ưu hóa bầy đàn
R^2	Coefficient of Determination	Hệ số xác định R bình phương
RMSE	Root Mean Square Error	Căn bậc hai của sai số bình phương trung bình
RNN	Recurrent Neural Network	Mạng nơ-ron hồi tiếp
SARIMA	Seasonal Autoregressive Integrated Moving Average	Mô hình tự hồi quy tích hợp trung bình trượt theo mùa
SVM	Support Vector Machine	Máy học vector hỗ trợ
SVR	Support Vector Regression	Hồi quy vector hỗ trợ
VAR	Vector Autoregression	Mô hình vector tự hồi quy
VECM	Vector Error Correction Model	Mô hình vector hiệu chỉnh sai số

XGBoost	Extreme Gradient Boosting	Thuật toán tăng cường độ dốc cực độ
---------	---------------------------	--

DANH MỤC CÁC BẢNG BIỂU

Bảng 1.1. Bảng tổng hợp biến số tiêu biểu tác động đến giá vàng	11
Bảng 1.2. Bảng so sánh các phương pháp tiếp cận dự đoán giá vàng	16
Bảng 3.1. Bảng thiết lập cấu hình không gian tìm kiếm cho PSO.....	44
Bảng 3.2. Bảng tổng hợp các chỉ số đánh giá hiệu năng	51

DANH MỤC CÁC HÌNH ẢNH

Hình 1.1. Ví dụ cho Bài toán Dự đoán giá vàng - GPP	9
Hình 2.1. Mô tả chuyển động của một cá thể trong thuật toán PSO, cá thể di chuyển hướng về phía vị trí tốt nhất toàn cục và vị trí tốt nhất hiện tại của chính cá thể đó	31
Hình 2.2. Hình Lưu đồ thuật toán (Flowchart) của mô hình lai PSO-LSTM	34
Hình 3.1. Ma trận tương quan giữa các biến tài chính và giá vàng	41
Hình 3.2. Kết quả dự báo của mô hình PSO-LSTM Bộ 1 trên tập Test Benchmark	46
Hình 3.3. Kết quả dự báo của mô hình PSO-LSTM Bộ 2 trên tập Test Benchmark	47
Hình 3.4. Kết quả dự báo của mô hình PSO-LSTM Bộ 3 trên tập Test Benchmark	48
Hình 3.5. Kết quả dự báo của mô hình PSO-LSTM Bộ 4 trên tập Test Benchmark	50
Hình 3.6. Biểu đồ so sánh PSO-LSTM (Bộ 4) và LSTM Baseline trên tập Test Benchmark	51

MỤC LỤC

LỜI CAM ĐOAN	i
LỜI CẢM ƠN	ii
DANH MỤC CÁC KÝ HIỆU, CÁC CHỮ VIẾT TẮT	iii
DANH MỤC CÁC BẢNG BIỂU	vi
DANH MỤC CÁC HÌNH ẢNH	vii
MỤC LỤC.....	viii
MỞ ĐẦU.....	1
1. Lý do chọn đề tài.....	1
2. Tổng quan.....	1
3. Mục đích và nhiệm vụ nghiên cứu	3
4. Đối tượng và phạm vi nghiên cứu.....	4
5. Phương pháp nghiên cứu.....	4
6. Giả thuyết khoa học.....	5
7. Những đóng góp mới của đề tài	6
8. Cấu trúc của Đồ án chuyên ngành.....	6
CHƯƠNG 1: TỔNG QUAN VỀ BÀI TOÁN DỰ ĐOÁN GIÁ VÀNG.....	8
1.1. Định nghĩa, phát biểu bài toán	8
1.1.1. Phát biểu bài toán dự báo và tối ưu hóa	8
1.1.2. Các khái niệm liên quan	9
1.1.3. Các yếu tố ảnh hưởng đến giá vàng	12
1.2. Ứng dụng của bài toán	12
1.3. Các nghiên cứu liên quan đến bài toán	13
1.3.1. Nhóm phương pháp thống kê truyền thống	13

1.3.2. Nhóm phương pháp học máy	14
1.3.3. Nhóm phương pháp học sâu.....	14
1.3.4. Nhóm mô hình lai và thuật toán Metaheuristic	15
1.3.5. Tổng kết đánh giá chung về các cách tiếp cận	15
1.4. Tiêu chí đánh giá các thuật toán.....	17
1.5. Các biến thể của bài toán.....	18
1.5.1. Dựa trên khung giờ thời gian dự báo	18
1.5.2. Dựa trên tính chất của giá trị dự báo.....	18
1.5.3. Dựa trên các yếu tố đầu vào	19
1.6. Khảo sát dữ liệu thực nghiệm chuẩn	19
1.6.1. Các nguồn dữ liệu sơ cấp và uy tín quốc tế	19
1.6.2. Hệ thống dữ liệu đa biến (Exogenous Variables)	20
1.6.3. Đặc điểm của tập dữ liệu thực nghiệm chuẩn	20
1.7. Lựa chọn dữ liệu thực nghiệm cho đề tài.....	20
1.8. Tóm tắt chương 1	21
CHƯƠNG 2: ĐỀ XUẤT THUẬT TOÁN BẦY ĐÀN GIẢI BÀI TOÁN DỰ ĐOÁN GIÁ VÀNG.....	22
2.1. Cơ sở lý thuyết về các thuật toán	22
2.2. Mạng bộ nhớ dài - ngắn (Long Short-Term Memory - LSTM).....	23
2.2.1. Lý thuyết:	23
2.2.2. Sự tiến hóa của cấu trúc bộ nhớ LSTM (Evolution of LSTM Architecture) 24	
2.2.3. Quá trình Lan truyền xuôi (Forward Pass):	26
2.3. Thuật toán Metaheuristic.....	28
2.3.1. Giới thiệu thuật toán Metaheuristic.....	28

2.3.2. Tiêu chí đánh giá thuật toán Metaheuristic	29
2.4. Thuật toán Tối ưu hóa bầy đàn.....	30
2.5. Xây dựng thuật giải	33
2.6. Thực nghiệm và đánh giá	36
2.7. Tóm tắt chương 2	37
CHƯƠNG 3: THỰC NGHIỆM VÀ ĐÁNH GIÁ.....	38
3.1. Môi trường thực nghiệm	38
3.1.1. Google Colab	38
3.1.2. Các thư viện được sử dụng	39
3.2. Hệ thống dữ liệu thực nghiệm.....	40
3.2.1. Nguồn gốc và đặc điểm dữ liệu	40
3.2.2. Phân tích tương quan	41
3.3. Thiết kế thực nghiệm	42
3.3.1. Thu thập và tiền xử lý	42
3.3.2. Cấu trúc bộ dữ liệu đầu vào (Windowing).....	42
3.3.3. Phân chia tập dữ liệu.....	43
3.3.4. Tối ưu hóa siêu tham số bằng PSO	43
3.4. Kết quả thực nghiệm	45
3.5. Đánh giá kết quả thực nghiệm	51
3.6. Tóm tắt chương 3	53
KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	54
Kết luận	54
Hướng phát triển	54
DANH MỤC TÀI LIỆU THAM KHẢO.....	56

MỞ ĐẦU

1. Lý do chọn đề tài

Vàng đã giữ vai trò nền tảng trong lịch sử tiền tệ, hoạt động như thước đo giá trị, luôn được trao đổi mua bán với một ý nghĩa là hàng hóa có giá trị trong xuyên suốt lịch sử. Với sự phát triển mở rộng của hệ thống ngân hàng, các loại thị trường tiền tệ và các tổ chức tài chính đã góp phần củng cố thêm vị thế của thị trường vàng trên toàn cầu. Thế nhưng giá vàng tăng giảm có tuân theo quy tắc, chịu sự chi phối chính bởi quan hệ cung - cầu, lãi suất, tỷ giá USD và tình hình chính trị - kinh tế toàn cầu, thay vì ngẫu nhiên.

Giá vàng thường tăng khi lạm phát cao, bất ổn địa chính trị, và giảm khi lãi suất tăng (nhà đầu tư chuyển sang kênh sinh lời khác).

Việc các thuật toán trí tuệ nhân tạo đã cung cấp nền tảng để đưa ra dự đoán thị trường chính xác, giúp các nhà đầu tư gia tăng lợi nhuận. Hiểu được mối quan hệ phức tạp giữa các biến số kinh tế cho phép đánh giá tốt hơn sự thay đổi giá cả, nơi mà sự xáo trộn trong cung và cầu gây ra những biến động giá đáng kể.

Tuy nhiên, các mô hình trí tuệ nhân tạo truyền thống thường gặp khó khăn trong việc tìm ra bộ tham số tối ưu hoặc dễ rơi vào cực trị cục bộ khi xử lý dữ liệu vàng có độ nhiễu cao. Do đó, việc ứng dụng thuật toán theo hướng tiếp cận Metaheuristic là giải thuật bày đàn để tối ưu hóa quá trình huấn luyện mô hình dự báo là vô cùng cấp thiết. Điều này không chỉ giúp gia tăng độ chính xác mà còn giải quyết bài toán tối ưu hóa đa mục tiêu trong môi trường dữ liệu thời gian thực biến động liên tục

2. Tổng quan

Hiện có nhiều phương pháp để giải bài toán dự đoán giá vàng, mà chủ yếu là tiếp cận theo bốn hướng chính sau đây:

Thứ nhất là các phương pháp thống kê cổ điển: Diễn hình của hướng tiếp cận này là các mô hình tự hồi quy và các mô hình phương sai thay đổi. Ưu điểm của

hướng tiếp cận này là dựa trên cấu trúc toán học chặt chẽ, có tính giải thích cao và cho phép phân tích các thành phần xu hướng của dữ liệu. Hạn chế của hướng tiếp cận này là các mô hình này thường dựa trên dữ liệu giả định có tính chất tuyến tính và phương sai không đổi. Tuy nhiên, thị trường vàng thực tế lại mang tính phi tuyến tính và có nhiễu rất cao, dẫn đến độ chính xác kém khi thị trường có những biến động mạnh về kinh tế.

Thứ hai là các phương pháp sử dụng mô hình học máy truyền thống: Điển hình cho hướng tiếp cận này là các thuật toán như Support Vector Regression , Random Forest và XGBoost. Ưu điểm của hướng tiếp cận này là có khả năng xử lý tốt các mối quan hệ phi tuyến phức tạp và hoạt động hiệu quả với các tập dữ liệu có kích thước vừa phải. Hạn chế của hướng tiếp cận này là hiệu suất của mô hình phụ thuộc rất lớn vào quá trình lựa chọn đặc trưng, xử lý chất lượng dữ liệu đầu vào và đưa quyết định dựa trên kích thước dữ liệu. Điều này đòi hỏi sự can thiệp đáng kể của các chuyên gia có kinh nghiệm và kiến thức chuyên môn sâu về tài chính để xác định các biến số đầu vào phù hợp.

Thứ ba là các phương pháp học sâu: Xu hướng giải quyết bài toán của hướng tiếp cận này là tập trung vào các mạng nơ-ron có cấu trúc phức tạp đặc biệt là sử dụng các mô hình mạng nơ-ron có khả năng sử dụng cơ chế hồi quy để ghi nhớ thông tin từ quá khứ như là RNN, LSTM và GRU để xử lý dữ liệu chuỗi thời gian. Ưu điểm của hướng tiếp cận này có khả năng tự động học các quy luật phụ thuộc dài hạn trong dữ liệu mà không cần trích xuất đặc trưng thủ công, đặc biệt là các dữ liệu phức tạp và kích thước dữ liệu lớn. Hạn chế của hướng tiếp cận này thực sự là một thách thức về mặt tài nguyên sử dụng khi đòi hỏi lượng dữ liệu huấn luyện rất lớn và công suất tính toán cao. Ngoài ra, mô hình dễ rơi vào tình trạng quá khớp và được coi là một "hộp đen" khó giải thích về mặt cơ chế kinh tế.

Thứ tư là phương pháp lai và Metaheuristic: Đây là hướng tiếp cận hiện đại, kết hợp sức mạnh dự đoán của các mạng học sâu với khả năng tối ưu hóa của các thuật toán theo hướng tiếp cận metaheuristic. Ưu điểm của hướng tiếp cận này là sự kết hợp này giúp khắc phục nhược điểm của các phương pháp truyền thống bằng cách

sử dụng thuật toán Metaheuristic để tối ưu hóa bộ tham số hoặc trọng số mạng nơ-ron. Điều này giúp mô hình tránh được việc rơi vào các cực trị cục bộ và tăng khả năng hội tụ toàn cục. Hướng tiếp cận này không chỉ gia tăng độ chính xác trong dự báo mà còn là cơ sở quan trọng để giải quyết các bài toán tối ưu hóa đa mục tiêu trong môi trường dữ liệu thời gian thực biến động liên tục.

Tóm lại, trong phạm vi môn học đồ án chuyên ngành, bên cạnh việc khảo sát các hướng tiếp cận dự báo từ thống kê cổ điển đến học sâu của các công trình đi trước, chúng tôi tập trung vào việc nghiên cứu và đề xuất ứng dụng thuật toán Metaheuristic để giải bài toán dự báo giá vàng dựa trên dữ liệu thời gian thực.

Với hướng tiếp cận này, nghiên cứu của chúng tôi không đặt kỳ vọng cao về việc đạt đến độ chính xác dự báo cao nhất hiện tại, mà chủ yếu là học hỏi cách thức tiếp cận, phân tích và giải quyết một bài toán thực tế có độ nhiễu và tính phức tạp cao bằng các kiến thức chuyên ngành đã tích lũy được trong suốt quá trình học tập tại trường. Đây thực sự là một thử thách lớn trong việc làm chủ các thuật toán tối ưu hóa hiện đại; đồng thời cũng là cơ sở quan trọng để chúng tôi hy vọng có thể phát triển thêm các nghiên cứu sâu hơn về các hệ thống hỗ trợ ra quyết định thông minh trong tương lai.

3. Mục đích và nhiệm vụ nghiên cứu

Mục đích nghiên cứu:

Nghiên cứu và xây một thuật toán tối ưu theo hướng tiếp cận metaheuristic để cải thiện độ chính xác trong việc giải quyết bài toán dự đoán giá vàng theo thời gian thực bằng cách tối ưu bộ tham số mô hình, từ đó có những nhận định đánh giá khách quan về độ chính xác, hiệu suất cũng như là độ sai lệch của thuật toán này so với các hướng tiếp cận khác.

Nhiệm vụ nghiên cứu:

Nghiên cứu phân tích lý thuyết và các đặc trưng của bài toán dự đoán giá vàng, khảo sát các hướng tiếp cận bằng các phương pháp học máy, các phương pháp học

sâu thông thường để đánh giá so với hướng tiếp cận metaheuristic tối ưu cải thiện độ chính xác đã được đề cập mục trên, xây dựng chương trình cho các thuật toán và đánh giá độ chính xác của thuật toán này trên bộ dữ liệu thử nghiệm.

4. Đối tượng và phạm vi nghiên cứu

Khách thể nghiên cứu:

Sử dụng thuật toán bầy đàn giải quyết bài toán dự đoán giá vàng theo dữ liệu thời gian thực.

Đối tượng nghiên cứu:

- Bài toán dự đoán giá vàng
- Dữ liệu giá vàng: giá vàng thế giới và Việt Nam, dữ liệu lịch sử theo chuỗi thời gian
- Thuật toán Tối ưu hóa bầy đàn
- Mô hình dự đoán là LSTM được tối ưu bởi thuật toán Tối ưu hóa bầy đàn

Phạm vi nghiên cứu:

- Bài toán dự đoán giá vàng thuộc lớp bài toán dự đoán chuỗi thời gian
- Sử dụng thuật toán bầy đàn để:
- Tối ưu tham số mô hình dự đoán, cải thiện độ chính xác dự đoán giá vàng.
- Phạm vi dữ liệu: dữ liệu lịch sử giá vàng trong một khoảng thời gian xác định.

5. Phương pháp nghiên cứu

Phương pháp nghiên cứu lý thuyết: nghiên cứu tài liệu, phân tích tổng hợp lý thuyết từ sách, tài liệu, luận văn chuyên ngành về thuật toán bầy đàn và các đặc trưng của bài toán dự đoán giá vàng theo thời gian thực.

Phương pháp thực nghiệm: cài đặt môi trường thực nghiệm; sử dụng hệ thống dữ liệu thực nghiệm chuẩn để tiến hành thực nghiệm và đánh giá.

Phương pháp định lượng: đánh giá kết quả dự đoán thông qua các chỉ số đánh giá: sai số tuyệt đối trung bình (MAE), sai số bình phương trung bình (RMSE). So sánh kết quả đạt được với một số hướng tiếp cận khác.

Phương pháp hỏi chuyên gia: thường xuyên trao đổi, tham khảo ý kiến của giảng viên hướng dẫn trong suốt quá trình nghiên cứu.

6. Giả thuyết khoa học

Giá vàng vốn chịu tác động phức tạp từ các biến số vĩ mô (lạm phát, lãi suất Fed, biến động địa chính trị) tạo nên các chuỗi thời gian có tính phi tuyến và nhiễu mạnh. Dựa vào bản chất ấy và đặc tính tối ưu hóa bầy đàn, nghiên cứu đề xuất các giả thuyết sau:

Tính thích nghi phi tuyến:

Giả thuyết cho rằng việc sử dụng thuật toán Bầy đàn sẽ giúp mô hình vượt qua các giới hạn của phương pháp thống kê truyền thống bằng cách tự động dò tìm các "điểm tối ưu toàn cục" trong việc xác lập trọng số và tham số mạng nơ-ron.

Cơ chế tự tổ chức và hội tụ:

Dựa trên nguyên lý tương tác giữa các cá thể trong đàn, thuật toán PSO có khả năng cân bằng giữa việc khám phá các vùng không gian dữ liệu mới và khai thác các giá trị tiềm năng đã biết; cho phép mô hình đạt được tốc độ hội tụ nhanh, phù hợp với yêu cầu xử lý luồng dữ liệu thời gian thực (real-time stream) vốn đòi hỏi độ trễ thấp nhất.

7. Những đóng góp mới của đề tài

Nâng cao độ tin cậy trong dự báo:

Việc ứng dụng thuật toán Bầy đàn vào bài toán dự đoán giá vàng sẽ làm giảm đáng kể các sai số dự báo định lượng (như RMSE, MAE) so với các mô hình chưa qua tối ưu hóa và tạo nền tảng cho các hệ thống hỗ trợ quyết định trong giao dịch tài chính với độ chính xác cao hơn.

Tính ứng dụng linh hoạt:

Nghiên cứu chứng minh một mô hình được tinh chỉnh bởi PSO còn có khả năng mở rộng, thích nghi với các loại tài sản tài chính có độ biến động tương tự vàng. Điều này khẳng định vai trò của các thuật toán giải gần đúng trong việc giải quyết các bài toán tối ưu tổ hợp phức tạp trên thị trường thực tế.

8. Cấu trúc của Đồ án chuyên ngành

Ngoài phần mở đầu, kết luận, danh mục tài liệu tham khảo và phụ lục, ĐACN gồm có 3 chương:

Chương 1: Tổng quan về bài toán dự đoán giá vàng

Đây là chương chúng tôi trình bày về các định nghĩa của bài toán cần giải quyết, các chỉ số đánh giá, dữ liệu thực nghiệm, các yếu tố phụ thuộc và các công trình nghiên cứu liên quan cũng được nhắc đến ở chương này. Cuối chương sẽ là phần chúng tôi trình bày về ý tưởng áp dụng thuật toán để giải bài toán và các chỉ số đánh giá được lựa chọn.

Chương 2: Đề xuất thuật toán Tối ưu hóa bầy đàn giải bài toán dự đoán giá vàng

Đây là chương chúng tôi sẽ giải thích về các lý thuyết cho người đọc về thuật toán chúng tôi áp dụng. Từ những quy trình chung cho đến chi tiết công thức, cơ sở tri thức toán học nằm đằng sau các phương pháp biểu diễn đặc trưng cho đến các thuật toán Tối ưu hóa bầy đàn và mô hình LSTM sẽ được trình bày rõ ràng và cụ thể.

Chương 3: Thực nghiệm và đánh giá

Đây là chương tôi sẽ tiến hành thực nghiệm và đánh giá mức độ hiệu quả của thuật toán PSO trong việc tối ưu siêu tham số cho mô hình dự đoán LSTM.

CHƯƠNG 1: TỔNG QUAN VỀ BÀI TOÁN DỰ ĐOÁN GIÁ VÀNG

1.1. Định nghĩa, phát biểu bài toán

1.1.1. Phát biểu bài toán dự báo và tối ưu hóa

Bài toán Dự đoán giá vàng (Gold Price Prediction - GPP) là một dạng bài toán dự báo chuỗi thời gian dựa trên dữ liệu lịch sử của thị trường (Time Series Forecasting). Cho một chuỗi các giá trị quan sát của giá vàng trong quá khứ $X = \{x_1, x_2, \dots, x_t\}$.

Để biểu diễn bài toán một cách ngắn gọn, ta định nghĩa vector đầu vào s_t đại diện cho cửa sổ quan sát (look-back window) tại thời điểm t [1]:

$$s_t = [x_t, x_{t-1}, \dots, x_{t-k}]^T$$

Mục tiêu cốt lõi là tìm ra một hàm số f để dự báo giá trị x_{t+h} tại thời điểm tương lai h [2]:

$$x_{t+h} = f(s_t, \phi)$$

Trong đó:

- x_{t+h} : Giá trị dự báo tại thời điểm t cho tương lai h bước.
- s_t : Vector chứa các giá trị trễ của giá vàng từ hiện tại ngược về quá khứ.
- k : Độ dài của cửa sổ quan sát (số lượng bước trễ được đưa vào mô hình).
- h : Khoảng thời gian dự báo (ví dụ: dự báo cho 1 ngày hoặc 1 tuần tới).
- ϕ : Các biến ngoại sinh bổ trợ đóng vai trò tác động đến xu hướng giá (như chỉ số DXY, lãi suất, tin tức địa chính trị...).

Về mặt kỹ thuật, bài toán GPP mô tả mối quan hệ giữa các biến số thị trường và các đặc trưng nội tại để quyết định giá trị vàng. Hình 1.1 minh họa kết quả dự báo của mô hình: trong đó, đường màu xanh biểu diễn giá vàng thực tế trên thị trường và đường màu cam biểu diễn giá trị do hệ thống dự đoán. Sự chênh lệch giữa hai đường này phản ánh hiệu quả và độ chính xác của thuật toán được sử dụng.

Bài toán GPP có thể được mô tả bằng một tập hợp các biến số thị trường, trong đó các giá trị lịch sử tương ứng với dữ liệu đầu vào, và mối quan hệ giữa chúng tương ứng với các đặc trưng (features) quyết định giá trị vàng. Lời giải tối ưu của bài toán

là việc xác định quy luật biến động nhằm tối thiểu hóa sai số giữa giá trị dự đoán và giá trị thực tế [3].



Hình 1.1. Ví dụ cho Bài toán Dự đoán giá vàng - GPP

1.1.2. Các khái niệm liên quan

Các khái niệm được sử dụng trong nghiên cứu bao gồm:

1. Nhóm khái niệm Thị trường và Tài sản

- **XAU/USD (hay XAUUSD):** Là ký hiệu tỷ giá hối đoái giữa vàng (XAU) và đồng Đô la Mỹ (USD). Chỉ số này cho biết số lượng USD cần thiết để mua một Ounce vàng. Trong đó, XAU là mã tiêu chuẩn quốc tế (ISO 4217) cho một Ounce troy vàng (khoảng 31.1 gram).
- **Biến động (Volatility):** Thể hiện mức độ và tốc độ thay đổi của giá vàng trong một khoảng thời gian nhất định. Đây là yếu tố then chốt quyết định độ khó của bài toán dự báo.

2. Nhóm khái niệm Dữ liệu và Tiền xử lý

- **Dữ liệu chuỗi thời gian (Time Series Data):** Tập hợp các quan sát về giá vàng được ghi lại theo trình tự thời gian liên tục. Đây là thành phần đầu vào (Input) chính của bài toán.

- **Giá đóng cửa (Closing Price):** Mức giá giao dịch cuối cùng trong một phiên (ngày, giờ). Trong nghiên cứu này, giá đóng cửa được chọn làm **biến mục tiêu** (Target variable) để mô hình đưa ra dự báo.
- **Độ trễ (Lag):** Kỹ thuật sử dụng các giá trị trong quá khứ ($P_{t-1}, P_{t-2}, \dots$) làm biến đầu vào để dự báo cho giá trị hiện tại (P_t).

3. Nhóm khái niệm Mô hình và Kỹ thuật Dự báo

- **Mạng nơ-ron hồi tiếp (RNN) & LSTM:** Kiến trúc mạng nơ-ron chuyên biệt cho dữ liệu chuỗi thời gian. Trong đó, LSTM (Long Short-Term Memory) là cải tiến giúp mô hình có khả năng ghi nhớ các phụ thuộc dài hạn, khắc phục hiện tượng mất mát thông tin trong các chuỗi dữ liệu vàng dài.
- **Tối ưu hóa (Optimization):** Quá trình tìm kiếm bộ tham số tốt nhất cho thuật toán nhằm tối thiểu hóa sai số dự báo.
- **Hàm mất mát (Loss Function):** Công thức đo lường độ lệch giữa giá trị dự báo (y') và giá trị thực tế (y). Nghiên cứu sử dụng hai chỉ số chính:

- + MAE (Mean Absolute Error): Trung bình trị tuyệt đối của sai số, cho biết mức độ lệch trung bình giữa giá dự báo và giá thực tế.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- + RMSE (Root Mean Squared Error): Căn bậc hai của trung bình bình phương sai số. RMSE phạt nặng các sai số lớn, rất quan trọng trong dự báo tài chính vì các cú "sốc" giá (outliers) có thể gây thiệt hại nặng nề.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- **Khớp quá mức (Overfitting):** Trạng thái mô hình học quá chi tiết trên dữ liệu huấn luyện (Training data) dẫn đến việc mất khả năng dự báo chính xác trên dữ liệu thực tế mới (Testing data).

4. Nhóm khái niệm Biến số liên thị trường

Để nâng cao độ chính xác, mô hình tích hợp các biến số kinh tế vĩ mô có tác động trực tiếp đến giá vàng:

Bảng 1.1. Bảng tổng hợp biến số tiêu biểu tác động đến giá vàng

Chỉ số	Mã (Ticker)	Mô tả và Ý nghĩa kinh tế
Gold Futures	GC=F	Giá vàng tương lai, phản ánh kỳ vọng của nhà đầu tư và tính thanh khoản của thị trường kim loại quý.
US Dollar Index	DX-Y.NYB	Thước đo sức mạnh đồng USD. Do vàng được định giá bằng USD, chỉ số này thường có tương quan nghịch biến cực mạnh với giá vàng.
WTI Crude Oil	CL=F	Giá dầu thô, đại diện cho chi phí đẩy và áp lực lạm phát toàn cầu; thường dịch chuyển cùng chiều với vàng trong dài hạn.
S&P 500 Index	^GSPC	Đại diện cho thị trường chứng khoán Mỹ. Phản ánh tâm lý nhà đầu tư giữa trạng thái mạo hiểm (Risk-on) và trú ẩn an toàn (Risk-off).

10Y Treasury Yield	[^] TNX	Lợi suất trái phiếu chính phủ Mỹ kỳ hạn 10 năm. Đây là "chi phí cơ hội" của việc nắm giữ vàng; lợi suất tăng làm giảm tính hấp dẫn của tài sản không sinh lãi như vàng.
---------------------------	------------------	---

1.1.3. Các yếu tố ảnh hưởng đến giá vàng

Dựa trên các biến số đã nêu, biến động của giá vàng là kết quả tổng hòa từ sự tương tác phức tạp của các yếu tố kinh tế và địa chính trị:

- Chỉ số đồng đô la Mỹ (DXY): Vàng được định giá bằng USD, do đó thường có mối quan hệ nghịch biến với sức mạnh đồng tiền này.
- Lạm phát và Lãi suất: Khi lạm phát tăng cao hoặc lãi suất thực giảm, vàng trở thành công cụ lưu trữ giá trị hấp dẫn hơn.
- Tình hình địa chính trị: Các cuộc xung đột vũ trang, căng thẳng thương mại toàn cầu thúc đẩy tâm lý "trú ẩn an toàn" (Safe Haven), làm tăng nhu cầu về vàng.
- Cung - Cầu thị trường: Bao gồm sản lượng khai thác tại các mỏ vàng và nhu cầu từ ngành trang sức hoặc công nghiệp bán dẫn.

1.2. Ứng dụng của bài toán

Không chỉ là một bài toán khoa học dữ liệu thuần túy, dự đoán giá vàng mang tính ứng dụng thực tiễn cao trong nhiều lĩnh vực tài chính:

Quản trị rủi ro (Risk Management): Giúp các tổ chức tài chính và ngân hàng dự báo các đợt biến động mạnh để điều chỉnh danh mục đầu tư, giảm thiểu thiệt hại khi thị trường bất ổn.

Hỗ trợ quyết định đầu tư (Investment Decision Support): Cung cấp tín hiệu cho các nhà đầu tư cá nhân và quỹ phòng hộ xác định thời điểm mua/bán tối ưu.

Hoạch định chính sách kinh tế: Các ngân hàng trung ương sử dụng dự báo giá vàng như một chỉ báo về lạm phát và sức khỏe của đồng nội tệ để đưa ra các quyết định về dự trữ ngoại hối.

1.3. Các nghiên cứu liên quan đến bài toán

Dựa trên lịch sử nghiên cứu, các phương pháp dự đoán giá vàng có thể được chia thành 4 nhóm tiếp cận chính:

- Nhóm phương pháp thống kê truyền thống
- Nhóm phương pháp học máy
- Nhóm phương pháp học sâu
- Nhóm mô hình lai (Hybrid models) và thuật toán tối ưu hóa Metaheuristic

1.3.1. Nhóm phương pháp thống kê truyền thống

Nhóm này tập trung khai thác thông tin nội tại từ chuỗi giá vàng lịch sử và thiết lập các mối quan hệ tuyến tính.

- **Mô hình Hồi quy tuyến tính (Linear/Multiple Regression):** Được sử dụng để thiết lập mối quan hệ giữa giá vàng (biến phụ thuộc) và các yếu tố tác động (biến độc lập). Dù đơn giản, một số thực nghiệm cho thấy hồi quy tuyến tính đôi khi vượt trội hơn các thuật toán phức tạp trong việc dự báo dữ liệu tài chính có tính biến động cao [5], [12].
- **Họ mô hình Box-Jenkins (ARIMA, SARIMA, ARIMAX):** Phân tích định lượng tính tương quan của dữ liệu trong quá khứ để đưa ra dự báo tương lai. Mô hình SARIMA được mở rộng để xử lý dữ liệu có tính chu kỳ/mùa vụ, trong khi ARIMAX cho phép tích hợp các biến ngoại sinh (như giá mở cửa, lạm phát) để tăng độ chính xác. Trong các điều kiện thị trường ổn định, ARIMA được chứng minh là có hiệu suất rất tốt, phản ánh việc giá quá khứ là yếu tố dự báo mạnh mẽ nhất cho giá tương lai [11].
- **Mô hình Phương sai thay đổi (ARCH/GARCH):** Được thiết kế chuyên biệt để đo lường và dự báo rủi ro, đặc biệt là giải quyết hiện tượng "cụm biến động" (volatility clustering) thường thấy ở giá vàng [14], [16].

- **Mô hình Vector tự hồi quy (VAR) và Vector hiệu chỉnh sai số (VECM):** Dùng để phân tích mối quan hệ đa biến, mô tả các tác động qua lại động và sự đồng liên kết (cointegration) dài hạn giữa giá vàng và các biến số kinh tế toàn cầu [12].

1.3.2. Nhóm phương pháp học máy

Các thuật toán học máy giúp khắc phục nhược điểm của mô hình tuyến tính bằng cách tự động trích xuất các quy luật phức tạp từ dữ liệu.

- **Cây quyết định (Decision Tree) và Rừng ngẫu nhiên (Random Forest):** Phân tích dữ liệu bằng cách chia tách các đặc tính phi tuyến tính. Random Forest tỏ ra mạnh mẽ và ổn định nhờ việc kết hợp kết quả từ nhiều cây quyết định, giảm phương sai và tránh tình trạng quá khớp (overfitting) [5], [6].
- **XGBoost:** Thuật toán tăng cường độ dốc (gradient boosting) xây dựng các mô hình tuần tự nhằm bù đắp sai số của các mô hình yếu trước đó, thường cho kết quả dự báo vượt trội với sai số thấp [5], [13].
- **Máy học Vector hỗ trợ (SVM/SVR) và K-Láng giềng gần nhất (KNN):** SVR sử dụng hàm kernel để ánh xạ dữ liệu lên không gian chiều cao, giúp xử lý tốt các giới hạn cực đoan của giá. Trong khi đó, KNN tìm kiếm sự tương đồng trong dữ liệu, mặc dù đôi khi gặp khó khăn với các cú sốc bất ngờ của thị trường [6], [13].

1.3.3. Nhóm phương pháp học sâu

Các mô hình học sâu đặc biệt hiệu quả trong việc nắm bắt các phụ thuộc thời gian dài hạn và các mẫu phi tuyến tính phức tạp.

- **Mạng Nơ-ron Nhân tạo (ANN / MLP):** Mô phỏng cách hoạt động của não người, mô hình này rất linh hoạt trong việc ánh xạ các đầu vào phức tạp thành dự báo đầu ra [10], [14].
- **Mạng bộ nhớ ngắn-dài hạn (LSTM) và Cổng hồi quy (GRU):** Đây là các biến thể tiên tiến của Mạng nơ-ron hồi quy (RNN). LSTM sử dụng cấu trúc các "cổng" (forget, input, output gate) để ghi nhớ thông tin dài hạn và bỏ qua

dữ liệu nhiều. LSTM và GRU thường áp đảo các mô hình thống kê truyền thống trong các khung thời gian ngắn, trung và dài hạn [7].

- **Mạng Nơ-ron Tích chập (CNN) và Bi-GRU/Bi-LSTM:** CNN có khả năng trích xuất các đặc trưng cục bộ xuất sắc, trong khi Bi-GRU và Bi-LSTM xử lý chuỗi dữ liệu theo cả hai hướng (từ quá khứ đến hiện tại và ngược lại) để tối ưu hóa việc học các phụ thuộc thời gian [8], [14].

1.3.4. Nhóm mô hình lai và thuật toán Metaheuristic

Xu hướng hiện đại là kết hợp đa phương pháp để triệt tiêu nhược điểm của từng mô hình đơn lẻ.

- **Mô hình lai (Hybrid Models):** Sự kết hợp như ARIMA-GARCH (kết hợp phân tích tuyến tính và tính toán phương sai biến động) hoặc quy trình 3 giai đoạn SARIMA-LSTM-RF cho độ chính xác cao hơn rõ rệt [8].
- **Thuật toán Metaheuristic:** Các thuật toán lấy cảm hứng từ tự nhiên (như Thuật toán Đom đóm-FA, Tối ưu hóa bướm đêm ngọn lửa-MFO, Tối ưu hóa bầy đàn-PSO) được sử dụng để tự động tìm ra các siêu tham số (hyperparameters) tối ưu nhất cho mạng nơ-ron. Phương pháp này (chẳng hạn như PSO-LSTM hoặc CNN-BiGRU-FA) giúp mạng nơ-ron tránh rơi vào bẫy cực tiểu cục bộ, giảm thiểu thời gian tính toán và đạt được độ chính xác rất cao [8], [9], [10].

1.3.5. Tổng kết đánh giá chung về các cách tiếp cận

Dưới đây là bảng so sánh ưu, nhược điểm của các phương pháp tiếp cận dự đoán giá vàng:

Bảng 1.2. Bảng so sánh các phương pháp tiếp cận dự đoán giá vàng

Phương pháp	Ưu điểm	Nhược điểm
Thống kê truyền thống	Đơn giản, dễ giải thích và có hiệu suất tốt khi thị trường ổn định [11]	Khó bắt kịp các biến động phi tuyến tính và các cú sốc bất ngờ của thị trường tài chính [6], [16]
Học máy	Khả năng xử lý dữ liệu nhiều tốt; độ chính xác thường cao hơn các mô hình hồi quy tuyến tính truyền thống [5], [6]	Yêu cầu tài nguyên tính toán lớn hơn và khó giải thích cơ chế ra quyết định hơn mô hình thống kê [10]
Học sâu	Hiệu quả vượt trội trong việc ghi nhớ các phụ thuộc thời gian dài hạn và xử lý dữ liệu phi cấu trúc [7], [17]	Cần lượng dữ liệu lớn để huấn luyện; dễ gặp hiện tượng quá khớp (overfitting) nếu không tối ưu tham số [17]
Mô hình lai	Tối ưu hóa được các siêu tham số tự động, giúp tăng độ chính xác và giảm sai số dự báo đáng kể [8], [9], [10]	Cấu trúc mô hình rất phức tạp; đòi hỏi thời gian huấn luyện và chuyên môn kỹ thuật cao để triển khai [14], [15]

Trong các hướng tiếp cận trên, các mô hình lai đang nhận được sự quan tâm đáng kể trong bài toán dự đoán chuỗi thời gian tài chính hiện nay. Các mô hình này kết hợp khả năng ghi nhớ chuỗi thời gian của các mô hình học sâu với các thuật toán tối ưu hóa metaheuristic nhằm cải thiện hiệu suất dự báo. Trong đó, mô hình LSTM kết hợp với thuật toán PSO được xem là một hướng tiếp cận tiềm năng.

Thuật toán PSO có khả năng hỗ trợ quá trình tìm kiếm bộ siêu tham số tối ưu cho mô hình học sâu, đồng thời góp phần giảm nguy cơ rơi vào cực trị cục bộ trong quá trình tối ưu. Nhờ đó, mô hình có thể cải thiện khả năng tổng quát hóa và nâng cao độ chính xác dự báo đối với dữ liệu chuỗi thời gian phức tạp như dữ liệu giá vàng.

Điều này cho thấy việc nghiên cứu và đánh giá khả năng áp dụng các thuật toán metaheuristic, đặc biệt là PSO, trong bài toán dự đoán giá vàng là một hướng nghiên cứu có ý nghĩa và cần được khảo sát thông qua thực nghiệm.

1.4. Tiêu chí đánh giá các thuật toán

Việc đánh giá hiệu suất của mô hình dự báo giá vàng không thể dựa trên cảm tính. Theo các nghiên cứu thực nghiệm, các chỉ số sau đây được đề xuất là tiêu chuẩn phù hợp để đo lường sai số và độ chính xác. Vì vậy, việc kết hợp các chỉ số (như RMSE, MAE, MAPE) là phương pháp thường được yêu cầu để có cái nhìn toàn diện về hiệu suất mô hình cũng như đánh giá độ hiệu quả so với các mô hình khác [18], [19], [20]:

- Sai số tuyệt đối trung bình (MAE): Phản ánh giá trị tuyệt đối của sự chênh lệch giữa giá trị dự báo và giá trị thực tế [4]. Chỉ số này cung cấp một cái nhìn trực quan về mức độ sai lệch trung bình của mô hình [20].
- Căn bậc hai sai số bình phương trung bình (RMSE): Do có cơ chế bình phương sai số, RMSE phạt nặng hơn đối với các độ lệch lớn, khiến nó đặc biệt nhạy cảm với các sai số lớn hoặc sự gia tăng phương sai. Trong thị trường vàng đầy biến động, một mô hình có RMSE thấp cho thấy khả năng nắm bắt tốt các "giá trị cực đoan" (extreme values), từ đó cung cấp các điểm mua và bán tiềm năng nhằm giảm thiểu rủi ro đầu tư [20].

- Sai số phần trăm tuyệt đối trung bình (MAPE): Thể hiện sai số dự đoán dưới dạng phần trăm của giá trị quan sát thực tế. Đặc tính này làm tăng khả năng diễn giải, giúp dễ dàng so sánh hiệu suất dự báo giữa các bối cảnh hoặc các bộ dữ liệu có thang đo khác nhau [20].
- Hệ số xác định (R^2): Đo lường mức độ phù hợp của mô hình so với biến thiên thực tế của dữ liệu, định lượng tỷ lệ phương sai (sự biến thiên) của biến phụ thuộc có thể được giải thích bởi mô hình [4], [20]. Giá trị R^2 càng gần 1 thể hiện khả năng giải thích dữ liệu của mô hình càng tốt [4].

1.5. Các biến thể của bài toán

Dự đoán giá vàng là bài toán phức tạp trong lĩnh vực tài chính định lượng. Tùy thuộc vào mục tiêu đầu tư, khung thời gian và yếu tố đầu vào, bài toán này được chia thành các biến thể khác nhau dựa trên cấu trúc dữ liệu và mục tiêu báo cáo.

1.5.1. Dựa trên khung giờ thời gian dự báo

Dự đoán giá vàng ngắn hạn: Tập trung vào việc dự báo biến động giá theo từng phút, giờ hoặc ngày. Biến thể này thường phục vụ cho các nhà đầu tư lướt sóng (day traders), nơi các mô hình cần độ nhạy cao với các tin tức tức thời và chỉ số kỹ thuật.

Dự đoán giá vàng dài hạn: Tập trung vào xu hướng giá theo tháng hoặc năm. Bài toán này thường bỏ qua các "nhiều" ngắn hạn và tập trung vào các yếu tố kinh tế vĩ mô như lạm phát, chính sách tiền tệ của các ngân hàng trung ương và tình hình địa chính trị toàn cầu.

1.5.2. Dựa trên tính chất của giá trị dự báo

Dự đoán giá trị điểm: Đây là biến thể phổ biến nhất, mục tiêu là tìm ra một con số cụ thể cho giá vàng tại một thời điểm trong tương lai. Ví dụ: "Giá vàng ngày mai sẽ là 2,150 USD/ounce".

Dự đoán khoảng tin cậy: Thay vì một con số duy nhất, bài toán này dự báo một khoảng giá trị mà giá vàng có khả năng rơi vào với một xác suất nhất định (ví dụ 95%). Biến thể này giúp nhà đầu tư quản trị rủi ro tốt hơn.

Dự đoán hướng biến động: Bài toán không tập trung vào con số cụ thể mà chỉ dự đoán xu hướng là Tăng (Up), Giảm (Down) hoặc Đi ngang (Sideways) so với mức giá hiện tại.

1.5.3. Dựa trên các yếu tố đầu vào

Việc phân loại các biến thể còn có thể dựa vào tập dữ liệu mà mô hình sử dụng để học:

Dự đoán dựa trên chuỗi thời gian đơn biến: Mô hình chỉ sử dụng dữ liệu giá vàng trong quá khứ để dự báo giá trị tương lai. Các phương pháp điển hình bao gồm ARIMA hoặc các mạng học sâu đơn giản như RNN/LSTM chỉ dùng đầu vào là cột giá.

Dự đoán dựa trên đa biến: Đây là biến thể phức tạp hơn, kết hợp giá vàng với các biến số tương quan khác như:

- Chỉ số đồng USD (DXY): Thường có mối quan hệ nghịch biến với vàng.
- Giá dầu thô và các loại hàng hóa khác.
- Lợi suất trái phiếu chính phủ.
- Chỉ số chứng khoán (S&P 500, Dow Jones).

1.5.4. Dựa trên kết hợp phân tích cảm xúc

Biến thể này tích hợp thêm dữ liệu phi cấu trúc như tin tức kinh tế, bài báo tài chính hoặc dữ liệu từ mạng xã hội. Các mô hình NLP (Xử lý ngôn ngữ tự nhiên) được sử dụng để trích xuất "tâm lý thị trường" nhằm tăng độ chính xác cho dự báo

1.6. Khảo sát dữ liệu thực nghiệm chuẩn

1.6.1. Các nguồn dữ liệu sơ cấp và uy tín quốc tế

1. **World Gold Council (Hội đồng Vàng Thế giới):** Cung cấp dữ liệu lịch sử chính thống về giá vàng, nhu cầu tiêu thụ và sản lượng khai thác toàn cầu. Đây là nguồn dữ liệu chuẩn cho các nghiên cứu dài hạn [23].
2. **London Bullion Market Association (LBMA):** Giá ấn định (Gold Fix) của LBMA được coi là chuẩn mực quốc tế cho các giao dịch vàng vật chất, thường được sử dụng trong các báo cáo tài chính chính thống.

3. **Yahoo Finance & Investing.com:** Hai nền tảng phổ biến nhất cung cấp dữ liệu giao dịch theo khung thời gian (ngày, giờ, phút) của cặp tỷ giá XAU/USD. Dữ liệu tại đây bao gồm giá mở cửa, đóng cửa, cao nhất, thấp nhất (OHLC) và khối lượng giao dịch [24].

1.6.2. Hệ thống dữ liệu đa biến (Exogenous Variables)

Để giải quyết biến thể bài toán đa biến, các hệ thống dữ liệu sau được sử dụng để thu thập các biến ngoại sinh:

1. **FRED (Federal Reserve Economic Data):** Nguồn dữ liệu của Cục Dự trữ Liên bang Mỹ, cung cấp các chỉ số kinh tế vĩ mô chuẩn như lãi suất (Fed Funds Rate), tỷ lệ lạm phát (CPI) và lợi suất trái phiếu chính phủ.
2. **U.S. Dollar Index (DXY):** Được trích xuất từ các sàn giao dịch ngoại hối lớn (Intercontinental Exchange - ICE).

1.6.3. Đặc điểm của tập dữ liệu thực nghiệm chuẩn

Một tập dữ liệu được coi là "chuẩn" cho bài toán GPP cần đáp ứng các tiêu chí kỹ thuật [16]:

1. **Tính liên tục:** Không có khoảng trống về thời gian (trừ ngày nghỉ lễ của thị trường).
2. **Độ phân giải (Granularity):** Tùy theo khung thời gian dự báo (Daily, Hourly hoặc Tick data).
3. **Độ dài lịch sử:** Thường từ 10 đến 20 năm để mô hình học được các chu kỳ kinh tế khác nhau.

1.7. Lựa chọn dữ liệu thực nghiệm cho đề tài

Trong nghiên cứu này, chúng tôi sử dụng tập dữ liệu được tổng hợp từ **Yahoo Finance API** và **FRED** trong giai đoạn từ ngày [Ví dụ: 15/01/2026] đến năm [Ví dụ: 15/03/2026]. Tập dữ liệu bao gồm:

1. **Dữ liệu đích:** Giá đóng cửa hàng ngày của XAU/USD.
2. **Dữ liệu đặc trưng:** Chỉ số DXY, giá dầu thô (WTI), chỉ số S&P 500 và lợi

suất trái phiếu 10 năm của Mỹ.

3. **Xử lý dữ liệu:** Dữ liệu được chuẩn hóa (Normalization) về khoảng $[0, 1]$ để đảm bảo sự hội tụ của các thuật toán học sâu như LSTM/GRU.

1.8. Tóm tắt chương 1

Trong bài toán này chúng tôi đã giới thiệu về bài toán dự đoán giá vàng, các biến thể quan trọng của bài toán và một số cách tiếp cận để giải bài toán này. Đây là cơ sở để nghiên cứu và xây dựng lời giải tối ưu cho bài toán “Dự đoán giá vàng theo dữ liệu chuỗi thời gian”, một biến thể của bài toán dự đoán giá vàng.

CHƯƠNG 2: ĐỀ XUẤT THUẬT TOÁN BẦY ĐÀN GIẢI BÀI TOÁN DỰ ĐOÁN GIÁ VÀNG

2.1. Cơ sở lý thuyết về các thuật toán

Dự báo giá vàng là một bài toán phức tạp do đặc tính phi tuyến tính, nhiều biến động và chịu ảnh hưởng bởi vô số các yếu tố không thể dự đoán trước. Để giải quyết bài toán này, các mô hình học sâu như Mạng bộ nhớ dài-ngắn (Long Short-Term Memory - LSTM) và Mạng nơ-ron tích chập (CNN) đã được chứng minh là có khả năng lập mô hình dữ liệu chuỗi thời gian hiệu quả hơn so với các mô hình thống kê truyền thống như ARIMA. Tuy nhiên, các mô hình học sâu thường gặp khó khăn trong việc thiết lập các siêu tham số (hyperparameters), đòi hỏi không gian khám phá rất lớn.

Để tối ưu hóa quá trình này, các thuật toán Metaheuristic lấy cảm hứng từ tự nhiên, đặc biệt là các thuật toán dựa trên trí tuệ bầy đàn (Swarm Intelligence), được đề xuất như một giải pháp cốt lõi. Thuật toán bầy đàn là các phương pháp tối ưu hóa dựa trên quần thể, mô phỏng hành vi của các loài sinh vật trong tự nhiên (như tối ưu hóa bầy đàn PSO, thuật toán đàn ong nhân tạo ABC, thuật toán đom đóm FA). Các thuật toán Metaheuristic cung cấp các chiến lược tối ưu hóa linh hoạt, không phụ thuộc vào bài toán cụ thể, giúp khám phá các không gian tham số phức tạp và có chiều dữ liệu cao để đạt được độ chính xác dự đoán và khả năng tổng quát hóa tốt hơn.

Việc kết hợp giữa mô hình mạng nơ-ron và các thuật toán Metaheuristic giúp tạo ra các mô hình lai mạnh mẽ, trong đó thuật toán bầy đàn đóng vai trò tìm kiếm bộ trọng số và siêu tham số tối ưu (như tỷ lệ học, kích thước batch, số lượng tế bào ẩn) nhằm giảm thiểu sai số dự báo.

2.2. Mạng bộ nhớ dài - ngắn (Long Short-Term Memory - LSTM)

2.2.1. Lý thuyết:

Long Short-Term Memory (LSTM) là một dạng kiến trúc đặc biệt của Mạng nơ-ron hồi tiếp (Recurrent Neural Network - RNN), được thiết kế để giải quyết vấn đề triệt tiêu đạo hàm (gradient vanishing) và bùng nổ đạo hàm (gradient explosion) khi học các phụ thuộc dài hạn trong dữ liệu chuỗi thời gian [1]. Trong bài toán dự báo giá vàng, LSTM thể hiện sự vượt trội nhờ khả năng ghi nhớ các biến động giá trong quá khứ và loại bỏ các nhiễu không cần thiết [4].

Thành phần cốt lõi của mạng LSTM là một khối bộ nhớ (memory cell) được điều khiển bởi cấu trúc các cổng (gates) bao gồm: cổng quên (forget gate), cổng đầu vào (input gate) và cổng đầu ra (output gate).

Cổng quên (Forget gate): Quyết định lượng thông tin từ trạng thái tế bào trước đó (C_{t-1}) sẽ được giữ lại hoặc loại bỏ. Đầu ra là một giá trị từ 0 (loại bỏ hoàn toàn) đến 1 (giữ lại hoàn toàn), Cổng quên có công thức toán học như sau [21]:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

Cổng đầu vào (Input gate) và Trạng thái ứng viên (Candidate): Xác định thông tin mới nào từ đầu vào hiện tại (x_t) sẽ được thêm vào tế bào. Cổng đầu vào có công thức toán học như sau [21]:

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$\tilde{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c)$$

Cập nhật trạng thái tế bào (Cell state update): Kết hợp thông tin cũ đã được lọc bởi cổng quên và thông tin mới từ cổng đầu vào [21]:


$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t$$

Cổng đầu ra (Output gate) và Trạng thái ẩn: Quyết định lượng thông tin từ trạng thái tế bào sẽ được xuất ra dưới dạng trạng thái ẩn (h_t) cho bước tiếp theo [21]:

$$ot = \sigma(Wo \cdot [ht-1, xt] + bo)$$

$$ht = ot * \tanh(Ct)$$

(Trong đó: W là ma trận trọng số, b là hệ số chệch (bias), σ là hàm kích hoạt sigmoid).



Hình 2.1. Hình vẽ sơ đồ cấu trúc chi tiết của một tế bào LSTM (LSTM cell) thể hiện sự luân chuyển của x_t , h_{t-1} , C_{t-1} đi qua các cổng sigmoid (σ) và $\tanh$.

2.2.2. Sự tiến hóa của cấu trúc bộ nhớ LSTM (Evolution of LSTM Architecture)

Cấu trúc Long Short-Term Memory (LSTM) phổ biến hiện nay (thường được gọi là "Vanilla LSTM") không phải là một thiết kế nguyên bản duy nhất mà là kết quả của một quá trình cải tiến và hoàn thiện liên tục qua nhiều giai đoạn:

Giai đoạn khởi đầu: Thiết kế sơ khai (1995 – 1997) được đề xuất bởi Sepp Hochreiter và Jürgen Schmidhuber, phiên bản LSTM đầu tiên ra đời nhằm giải quyết triệt để vấn đề suy giảm gradient (vanishing gradient) trong mạng RNN truyền thống [27]. Phiên bản sơ khai này giới thiệu khái niệm tế bào bộ nhớ chứa **Constant Error Carousel (CEC)**, giúp duy trì luồng sai số ổn định qua thời gian. Nhưng cấu trúc sơ khai chỉ gồm cổng vào (input gate) và cổng ra (output gate). Đặc biệt, phiên bản này

thiếu cổng quên (forget gate) và thuật toán huấn luyện là sự kết hợp giữa Lan truyền ngược qua thời gian (Backpropagation Through Time) và Học hồi quy thời gian thực (Real-Time Recurrent Learning) bị cắt bớt (truncated), khiến việc tối ưu hóa gặp nhiều giới hạn [27].

Sự ra đời của Cổng quên - Forget Gate (1999 – 2000), để giải quyết bài toán xử lý dữ liệu liên tục không phân đoạn, Felix Gers cùng các cộng sự đã bổ sung Forget Gate [28]. Vấn đề hiện giờ là do mạng không có cơ chế thiết lập lại, trạng thái nội tại của tế bào có thể tăng lên vô hạn, dẫn đến sự bão hòa và sụp đổ của mạng khi xử lý chuỗi dài. Vì vậy, với sự ra đời của Forget Gate cho phép mạng tự học cách xóa bỏ các thông tin không còn giá trị, giải phóng tài nguyên bộ nhớ. Đây được xem là cải tiến quan trọng nhất, giúp LSTM thực sự mạnh mẽ trong việc ghi nhớ các phụ thuộc xa (long-term dependencies).

Tiếp đến, tối ưu hóa thời gian với Peephole Connections (2000): Nhằm nâng cao độ chính xác về mặt định thời, Gers và Schmidhuber tiếp tục giới thiệu các **Kết nối điểm nhìn (Peephole Connections)** [29]. Các kết nối này cho phép các cổng (input, forget, output) trực tiếp truy cập vào trạng thái tế bào nội bộ (cell state) tại cùng một thời điểm. Cải tiến này đặc biệt hiệu quả cho các tác vụ yêu cầu sự phân biệt tinh tế giữa các khoảng cách thời gian, giúp mạng học được các cấu trúc nhịp điệu hoặc chu kỳ chính xác hơn.

Hoàn thiện cấu trúc "Vanilla LSTM" (2005), kiến trúc LSTM được chuẩn hóa hoàn toàn về mặt thuật toán nhờ nghiên cứu của Alex Graves và Schmidhuber [30]. Họ áp dụng quá trình Lan truyền ngược qua thời gian đầy đủ để huấn luyện mạng thay vì sử dụng gradient cắt bớt như trước đây. Việc sử dụng gradient đầy đủ giúp quá trình huấn luyện trở nên đáng tin cậy và chính xác hơn, đồng thời cho phép kiểm tra tính đúng đắn của thuật toán thông qua phương pháp sai phân hữu hạn [30]. Đây chính là phiên bản chuẩn được tích hợp trong hầu hết các thư viện Deep Learning hiện đại (như TensorFlow, PyTorch).

Các cải tiến sau khi phiên bản của Alex Graves và Schmidhuber năm 2005: Trong những năm gần đây, xu hướng nghiên cứu tập trung vào việc giảm chi phí tính toán mà vẫn giữ được hiệu suất gồm có: **CIFG (Coupled Input and Forget Gate)**, là bản cải tiến gộp chung cổng vào và cổng quên để giảm số lượng tham số [31]. **GRU (Gated Recurrent Unit)**: Do Cho và cộng sự phát triển, là một biến thể tối giản hóa mạnh mẽ bằng cách loại bỏ cổng ra và tích hợp trạng thái tế bào vào trạng thái ẩn (hidden state), giúp mô hình nhẹ hơn và huấn luyện nhanh hơn trên các tập dữ liệu nhỏ [32].

2.2.3. Quá trình Lan truyền xuôi (Forward Pass):

Quá trình lan truyền xuôi trong LSTM là sự kết hợp tính vi giữa các phép nhân ma trận và các phép toán từng phần tử (Hadamard product). Tại mỗi bước thời gian t , mạng nhận một vector đầu vào x_t và sử dụng trạng thái ẩn h_{t-1} cũng như trạng thái tế bào c_{t-1} từ bước trước đó để tính toán các giá trị mới.

Bước 1: Quyết định loại bỏ thông tin thông qua cổng quên: Cổng quên tính toán một vector có các giá trị trong khoảng 0 và 1. Giá trị 0 tương ứng với việc "quên hoàn toàn" và 1 tương ứng với việc "giữ lại hoàn toàn". Phương trình toán học được thiết lập như sau:

$$f_t = \sigma(W_f \cdot U_f h_{t-1} + b_f)$$

Trong đó,

- W_f là ma trận trọng số cho đầu vào
- U_f là ma trận trọng số hồi quy cho trạng thái ẩn
- b_f là vector độ lệch. Việc sử dụng hàm sigmoid là bắt buộc ở đây để tạo ra cơ chế đóng hoặc mở cổng.

Bước 2: Chuẩn bị thông tin mới qua cổng vào và vector ứng viên: Mạng cần xác định thông tin mới nào sẽ được giữ lại. Quá trình này gồm hai phần: cổng vào i_t quyết định vị trí cập nhật và vector ứng viên $\tilde{C}_t$ cung cấp nội dung cập nhật :

$$i_t = \sigma(W_i \cdot U_i h_{t-1} + b_i)$$

$$C_t = \tanh(W_c \cdot U_c h_{t-1} + b_c)$$

Lớp tanh ở đây đóng vai trò quan trọng trong việc chuẩn hóa các giá trị ứng viên vào khoảng $[-1, 1]$, giúp duy trì sự ổn định của trạng thái tế bào qua nhiều lần cộng dồn.

Bước 3: Cập nhật trạng thái tế bào nội tại: Đây là trái tim của cơ chế CEC. Trạng thái tế bào mới c_t được tính bằng cách kết hợp thông tin cũ đã qua bộ lọc cổng quên và thông tin mới qua bộ lọc cổng vào:

$$C_t = f_t \odot C_{t-1} + i_t \odot C_t$$

Ký hiệu $\odot$ đại diện cho phép nhân Hadamard (nhân từng phần tử). Do phép toán này chủ yếu là phép cộng, gradient khi truyền ngược qua c_t sẽ không bị triệt tiêu bởi các phép nhân ma trận như trong RNN thông thường. Điều này đảm bảo cho thông tin chảy xuyên suốt chuỗi thời gian.

Bước 4: Tạo đầu ra thông qua cổng ra: Cuối cùng, trạng thái ẩn h_t được trích xuất từ trạng thái tế bào sau khi đã đi qua một hàm tanh và được điều tiết bởi cổng ra o_t :

$$o_t = \sigma(W_o \cdot U_o h_{t-1} + b_o)$$

$$h_t = o_t \odot \tanh(C_t)$$

Trạng thái ẩn h_t vừa đóng vai trò là đầu ra của lớp tại thời điểm t , vừa là thông tin đầu vào cho bước tiếp theo $t+1$

2.3. Thuật toán Metaheuristic

2.3.1. Giới thiệu thuật toán Metaheuristic

Trong lĩnh vực tối ưu hóa kỹ thuật, các bài toán thực tế thường có không gian tìm kiếm rộng lớn, hàm mục tiêu không liên tục hoặc không có đạo hàm. Các thuật toán tối ưu hóa truyền thống (deterministic algorithms) như phương pháp đơn hình hay các phương pháp dựa trên đạo hàm (gradient-based) thường bộc lộ hạn chế khi đối mặt với các bài toán đa cực trị, dễ bị rơi vào trạng thái tối ưu cục bộ [22]. Để giải quyết các thách thức này, các thuật toán ngẫu nhiên (stochastic algorithms), tiêu biểu là Metaheuristic, đã trở thành một công cụ nghiên cứu quan trọng trong nhiều lĩnh vực ứng dụng thực tiễn như kỹ thuật, tài chính, trí tuệ nhân tạo.

Thuật ngữ "Heuristic" có nguồn gốc từ tiếng Hy Lạp mang nghĩa là "khám phá" thông qua phương pháp thử và sai. Các thuật toán này hướng tới việc tìm kiếm một lời giải đủ tốt trong một khoảng thời gian tính toán hợp lý. Trong khi đó, "Meta" có nghĩa là "vượt lên trên" hoặc "cấp độ cao hơn". Do đó, Metaheuristic được hiểu là những khung thuật toán cấp cao, đóng vai trò dẫn dắt và điều khiển các chiến lược heuristic đơn giản để tìm kiếm lời giải tối ưu trên phạm vi toàn cục [22].

Đặc điểm nổi bật của hầu hết các thuật toán metaheuristic là sự mô phỏng các cơ chế sinh học hoặc các hiện tượng trong tự nhiên. Trải qua hàng triệu năm tiến hóa, tự nhiên đã hình thành nên những quy luật tối ưu để giải quyết các vấn đề sinh tồn phức tạp, từ đó tạo nguồn cảm hứng cho việc xây dựng các thuật toán như thuật toán di truyền (GA), thuật toán tối ưu hóa bầy đàn (PSO) hay thuật toán tối ưu hóa đàn kiến (ACO) [15].

Các thuật toán metaheuristic có thể được phân loại theo nhiều tiêu chí khác nhau, trong đó phổ biến nhất là phân loại theo: dựa trên quần thể và dựa trên cá thể [22]:

- Thuật toán dựa trên quần thể: sử dụng một tập hợp các cá thể (chuỗi hoặc hạt) để tìm kiếm không gian nghiệm. Ví dụ điển hình là thuật toán di truyền và thuật toán tối ưu hóa bầy đàn, thuật toán tìm kiếm cục bộ (Local Search), thuật toán tìm kiếm Tabu (Tabu Search),...

- Thuật toán dựa trên cá thể: sử dụng một cá thể duy nhất di chuyển qua không gian thiết kế theo từng bước. Ví dụ như thuật toán luyện kim (Simulated Annealing), nơi một bước đi tốt hơn luôn được chấp nhận, trong khi một bước đi kém hơn có thể được chấp nhận với một xác suất nhất định.

Về mặt cơ chế, hiệu quả của một thuật toán metaheuristic phụ thuộc vào sự cân bằng giữa hai chiến lược [15], [22]:

- Sự chọn lọc: giúp tìm kiếm tập trung tại một vùng không gian cục bộ dựa trên thông tin của nghiệm tốt nhất đang có. Việc chọn lọc các nghiệm tốt nhất giúp đảm bảo rằng các nghiệm sẽ hội tụ dần về mức tối ưu.
- Tính ngẫu nhiên: gia tăng tính đa dạng của các giải pháp, cho phép thuật toán khám phá những vùng không gian nghiệm mới và tránh bị mắc kẹt tại các cực trị cục bộ.

2.3.2. Tiêu chí đánh giá thuật toán Metaheuristic

Một thuật toán metaheuristic được đánh giá có hiệu quả hay không dựa trên các tiêu chí cốt lõi sau:

- Độ chính xác và chất lượng lời giải: nhằm đánh giá khoảng cách giữa lời giải do thuật toán tìm được so với lời giải tối ưu toàn cục hoặc các kết quả tốt nhất từng được công bố. Chất lượng lời giải được phản ánh thông qua hai thông số: giá trị tối ưu nhất mà thuật toán đạt được sau một số lần thử nghiệm độc lập; giá trị trung bình phản ánh khả năng tìm kiếm trung bình của thuật toán, giúp đánh giá hiệu suất tổng thể qua nhiều lần chạy khác nhau.
- Tính hội tụ: phản ánh tốc độ và đặc điểm của thuật toán khi tiến gần đến vùng nghiệm tối ưu theo thời gian hoặc số thế hệ lặp. Một thuật toán tối ưu cần đảm bảo sự cân bằng giữa khả năng thăm dò ở giai đoạn đầu và hội tụ nhanh ở giai đoạn cuối để đạt được lời giải chính xác.
- Tính ổn định và độ tin cậy: do đặc thù mang tính ngẫu nhiên, kết quả của các thuật toán metaheuristic có thể biến động giữa các lần thực thi. Tính ổn định được đánh giá thông qua độ lệch chuẩn, chỉ số này càng thấp chứng tỏ thuật toán có tính nhất quán cao, ít bị ảnh hưởng bởi quá trình khởi tạo ngẫu nhiên.

- Hiệu suất tính toán: đánh giá mức độ tiêu tốn tài nguyên hệ thống để đạt được kết quả mong muốn.


2.4. Thuật toán Tối ưu hóa bầy đàn

Thuật toán Tối ưu hóa Bầy đàn (Particle Swarm Optimization - PSO , được phát triển bởi Kennedy và Eberhart vào năm 1995) là một trong những giải thuật metaheuristic phổ biến nhất, mô phỏng hành vi xã hội của bầy chim hoặc đàn cá khi tìm kiếm thức ăn [22].

Khác với GA, PSO không sử dụng các toán tử di truyền phức tạp như lai ghép hay đột biến. Thay vào đó, nó duy trì một quần thể, trong đó mỗi cá thể đóng vai trò là một lời giải tiềm năng di chuyển trong không gian tìm kiếm đa chiều. Vị trí của mỗi cá thể được điều chỉnh dựa trên hai yếu tố kinh nghiệm cốt lõi:

- Kinh nghiệm cá nhân (x_i^*): Vị trí tốt nhất mà chính cá thể đó từng đạt được trong lịch sử di chuyển (Personal Best).
- Kinh nghiệm bầy đàn (g^*): Vị trí tốt nhất mà bất kỳ cá thể nào trong toàn bộ quần thể đã đạt được (Global Best).

Sự kết hợp này tạo ra một cơ chế dẫn đường thông minh: các cá thể không chỉ "học" từ thành công của chính mình mà còn "chia sẻ" tri thức với cộng đồng. Về mặt lý thuyết tối ưu hóa, PSO thực hiện sự cân bằng giữa khai thác xung quanh x_i^* và g^* để hội tụ nhanh, đồng thời tận dụng các thành phần ngẫu nhiên để khám phá các vùng không gian mới, giúp tránh rơi vào các bẫy tối ưu cục bộ.



Hình 2.1. Mô tả chuyển động của một cá thể trong thuật toán PSO, cá thể di chuyển hướng về phía vị trí tốt nhất toàn cục và vị trí tốt nhất hiện tại của chính cá thể đó

Giả sử bầy đàn gồm n cá thể di chuyển trong không gian d chiều. Tại thời điểm t , cá thể thứ i có vị trí được ký hiệu là x_i^t và vận tốc là v_i^t . Quá trình tìm kiếm lời giải tối ưu được thực hiện thông qua việc cập nhật liên tục vận tốc và vị trí theo các công thức sau:

Công thức cập nhật vận tốc:

$$v_i^{t+1} = v_i^t + \alpha \epsilon_1 \odot [g^* - x_i^t] + \beta \epsilon_2 \odot [x_i^* - x_i^t]$$

Công thức cập nhật vị trí:

$$x_i^{t+1} = x_i^t + v_i^{t+1}$$

Trong đó:

- v_i^t : Vận tốc của cá thể i tại thời điểm t
- x_i^t : Vị trí hiện tại của cá thể i
- α, β : Các hằng số gia tốc
- ϵ_1, ϵ_2 : Các vector ngẫu nhiên có giá trị nằm trong khoảng $[0,1]$
- $\odot$: Phép nhân Hadamard
- x_i^* : Vị trí tốt nhất cá nhân
- g^* : Vị trí tốt nhất toàn cục

Cơ chế hoạt động: Trong thuật toán tối ưu hóa bầy đàn, mỗi cá thể (particle) đại diện cho một nghiệm tiềm năng (ví dụ: một bộ siêu tham số của mô hình LSTM) trong không gian tìm kiếm đa chiều. Quá trình tìm kiếm được định hướng bởi hai yếu tố: kinh nghiệm tốt nhất của chính cá thể đó và kinh nghiệm tốt nhất của toàn bộ bầy đàn tính đến thời điểm hiện tại. Các cá thể liên tục di chuyển, đánh giá độ thích nghi của mình và tự cập nhật vị trí cho đến khi thỏa mãn điều kiện dừng [15], [22].

Mã giả thuật toán PSO

Đầu vào: Hàm mục tiêu $f(x)$, với $x = (x_1, \dots, x_p)^T$.

1. Khởi tạo:

- Tạo ra n cá thể với các vị trí x_i^* và vận tốc v_i ngẫu nhiên trong không gian tìm kiếm
- Tìm g^* từ $\min\{f(x_1), \dots, f(x_n)\}$ (tại $t = 0$)

2. While (điều kiện chưa thỏa mãn) do {

$t = t + 1$ (thời gian giả hoặc bộ đếm số vòng lặp)

for lặp qua tất cả n cá thể và tất cả d chiều {

Tạo vận tốc mới v_i^{t+1} theo công thức cập nhật vận tốc

Tính vị trí mới x_i^{t+1} theo công thức cập nhật vị trí

Đánh giá hàm mục tiêu tại các vị trí mới x_i^{t+1}

Tìm giá trị tốt nhất hiện tại cho mỗi cá thể x_i^*

}

Tìm vị trí tốt nhất toàn cục hiện tại g^*

}


3. Đầu ra: kết quả cuối cùng x_i^* và g^* .

2.5. Xây dựng thuật giải

Thuật giải được đề xuất là sự kết hợp giữa mô hình học sâu (LSTM) đóng vai trò trích xuất đặc trưng và dự báo, cùng với thuật toán Metaheuristic bầy đàn đóng vai trò tối ưu hóa:

Vấn đề của mô hình LSTM truyền thống: Việc thiết lập các siêu tham số (hyperparameters) cho mạng LSTM như tốc độ học (learning rate), số lượng nơ-ron ẩn (hidden units), kích thước lô (batch size), và độ trễ (lookback) mang tính quyết định đến hiệu suất dự báo. Phương pháp thử - sai (trial and error) hay tìm kiếm dạng lưới (Grid Search) thông thường yêu cầu tài nguyên tính toán khổng lồ và dễ rơi vào nghiệm tối ưu cục bộ khi xử lý dữ liệu vàng có độ nhiễu cao.

Đề xuất quy trình lai PSO-LSTM để khắc phục hạn chế trên, nghiên cứu đề xuất sử dụng thuật toán tối ưu hóa bầy đàn (PSO) để tự động hóa quá trình tinh chỉnh các tham số của mô hình LSTM. Các thuật toán metaheuristic như PSO giúp mô hình đạt được sự cân bằng giữa khả năng khám phá (exploration) và khai thác (exploitation), từ đó nâng cao khả năng tổng quát hóa trên dữ liệu chuỗi thời gian tài chính.



Hình 2.2. Hình Lưu đồ thuật toán (Flowchart) của mô hình lai PSO-LSTM

Lưu đồ thuật toán (Flowchart) của mô hình lai PSO-LSTM mô tả hai giai đoạn chính của hệ thống : Giai đoạn Tối ưu hóa (được bọc trong khối nét đứt) và giai đoạn Dự báo.

Giai đoạn tối ưu hóa là giai đoạn sử dụng thuật toán PSO để tìm kiếm bộ siêu tham số tốt nhất thông qua quá trình lặp.

Giai đoạn dự báo là giai đoạn sử dụng bộ tham số tối ưu từ giai đoạn tối ưu hóa ở trước đó để huấn luyện mô hình LSTM cuối cùng và đưa ra kết quả dự đoán giá vàng.

Quy trình hoạt động của hệ thống đề xuất dự kiến dựa trên lưu đồ:

- 1. Preprocess data:** Giai đoạn tiền xử lý dữ liệu, bao gồm thu thập dữ liệu từ Yahoo Finance/FRED, xử lý giá trị khuyết thiếu và chuẩn hóa bằng MinMaxScaler về khoảng $[0, 1]$
- 2. Initialize the particle population (Khởi tạo quần thể):** Khởi tạo ngẫu nhiên một quần thể các cá thể, mỗi cá thể mang một vector vị trí đại diện cho một cấu hình siêu tham số của mạng LSTM .
- 3. Train LSTM & calculate fitness (Huấn luyện và tính hàm thích nghi):** Với mỗi cá thể, hệ thống sẽ xây dựng một mô hình LSTM dựa trên cấu hình tham số mà cá thể đó nắm giữ. Mô hình được huấn luyện trên tập dữ liệu vàng (Training set) và dự báo trên tập kiểm chứng (Validation set). Hàm mục tiêu (Fitness function) thường được chọn là sai số dự báo p (như RMSE hoặc MAE) nhằm mục đích cực tiểu hóa sai số.
- 4. Compare the fitness of particles and determine the optimal fitness of individuals and population :** So sánh sai số hiện tại với sai số tốt nhất của cá thể ($pBest$) và sai số tốt nhất của toàn bầy đàn ($gBest$) để lưu lại nghiệm ưu việt nhất.
- 5. Update speed and position of particle:** Di chuyển các cá thể trong không gian tham số dựa trên phương trình cập nhật của PSO để tìm kiếm vùng không gian mới tốt hơn. Cập nhật vận tốc và vị trí các hạt dựa trên các phương trình toán học đã thảo luận ở phần cơ sở toán học.
- 6. Up to the maximum generation times? (Điều kiện dừng):** Quá trình lặp lại cho đến khi đạt số vòng lặp tối đa hoặc $gBest$ không cải thiện đáng kể. Nghiệm $gBest$ cuối cùng sẽ là bộ tham số tối ưu dùng để xây dựng mô hình dự báo giá vàng chính thức trên tập kiểm tra (Test set).
- 7. Output optimal parameters & Substituting into the LSTM model:** Trích xuất bộ tham số tốt nhất và đưa vào mô hình dự báo chính thức.

- 8. Complete the prediction & Verify the model:** Thực hiện dự báo trên tập Test và đánh giá hiệu quả thông qua các chỉ số MAE, RMSE, R^2 .

2.6. Thực nghiệm và đánh giá

Để đánh giá khách quan độ chính xác và hiệu năng của mô hình đề xuất so với các phương pháp khác, nghiên cứu sử dụng các độ đo sai số tiêu chuẩn trong phân tích chuỗi thời gian. Kí hiệu y_i là giá trị thực tế của giá vàng, $\hat{y}_i$ là giá trị mô hình dự báo, và n là tổng số quan sát.

Sai số tuyệt đối trung bình (Mean Absolute Error - MAE): MAE đo lường trung bình của các chênh lệch tuyệt đối giữa giá trị dự báo và giá trị thực tế. MAE phản ánh quy mô của sai số tổng thể mà không bị nhạy cảm quá mức bởi các giá trị ngoại lai (outliers).

Căn bậc hai sai số toàn phương trung bình (Root Mean Square Error - RMSE): RMSE tính toán căn bậc hai của trung bình các bình phương sai số. Đặc điểm của RMSE là phạt nặng các sai số lớn, do đó nó cực kỳ hữu ích trong việc đánh giá khả năng của mô hình trong việc bám sát các biến động cực đoan của giá vàng. RMSE cũng thỏa mãn bất đẳng thức tam giác, làm cho nó trở thành một độ đo khoảng cách (distance metric) hợp lệ trong không gian toán học

Hệ số xác định (Coefficient of Determination - R^2): Hệ số R^2 thể hiện tỷ lệ phương sai của biến phụ thuộc (giá vàng) được giải thích bởi mô hình. Giá trị R^2 càng tiến gần đến 1 chứng tỏ khả năng dự báo của mô hình càng sát với thực tế thị trường. Mục tiêu của quá trình tối ưu hóa bằng thuật toán bầy đàn là tìm ra bộ tham số để cực tiểu hóa MAE, RMSE đồng thời đưa chỉ số R^2 tiệm cận về 1.

2.7. Tóm tắt chương 2

Trong chương 2, chúng tôi đã đi sâu vào cơ sở lý thuyết toán học của Mạng nơ-ron hồi tiếp LSTM và Thuật toán tối ưu hóa bầy đàn (PSO). Bằng cách phân tích những hạn chế trong việc thiết lập tham số thủ công của các mô hình học sâu truyền thống, chúng tôi đã đề xuất kiến trúc lai PSO-LSTM. Kiến trúc này sử dụng cơ chế tìm kiếm toàn cục của bầy đàn để tự động chọn lọc bộ siêu tham số tối ưu nhất, qua đó tăng cường khả năng học các mối quan hệ phi tuyến và biến động phức tạp của chuỗi thời gian giá vàng. Chương này cũng đã xác định rõ các hàm mục tiêu và các chỉ số đo lường hiệu suất (MAE, RMSE, R^2) làm cơ sở nền tảng cho việc cài đặt và phân tích thực nghiệm ở Chương 3.

CHƯƠNG 3: THỰC NGHIỆM VÀ ĐÁNH GIÁ

3.1. Môi trường thực nghiệm

3.1.1. Google Colab

Để đảm bảo tính linh hoạt và tận dụng hiệu năng tính toán cao cho thuật toán Bầy đàn, toàn bộ quá trình huấn luyện và thử nghiệm mô hình được tiến hành trên nền tảng điện toán đám mây Google Colaboratory (Google Colab).

Google Colab là một dịch vụ Jupyter Notebook được lưu trữ trên đám mây, được cung cấp bởi Google. Colab cho phép bạn viết và thực thi mã Python trong các trình duyệt web mà không cần cài đặt môi trường phát triển tích hợp (IDE) hoặc thực hiện cài đặt phần mềm trên máy tính cá nhân. [25]

Một số đặc điểm nổi bật của Google Colab [26]:

- **Môi trường không cần thiết lập:** Một dịch vụ Jupyter Notebook được lưu trữ trên đám mây, không cần thiết lập, với các môi trường chạy được cấu hình sẵn để bạn có thể bắt đầu ngay lập tức.
- **Máy chủ ảo và tài nguyên mạnh mẽ:** Nhận quyền truy cập miễn phí vào các tài nguyên tính toán mạnh mẽ, bao gồm GPU và TPU, để tăng tốc các dự án học máy.
- **Hợp tác tích hợp:** Dễ dàng chia sẻ sổ tay, quản lý phiên bản và kết nối với Google Drive để có trải nghiệm cộng tác tích hợp và toàn diện.
- **Giao diện dễ sử dụng:** Giao diện thân thiện với sinh viên, dễ sử dụng trên trình duyệt giúp giảm thời gian học hỏi cho người dùng mới, đồng thời đơn giản hóa việc chia sẻ cho cộng tác nhóm.
- **Đa nền tảng:** Có thể truy cập thông qua bất kỳ thiết bị nào có kết nối Internet, cho dù bạn đang ở bàn làm việc hay mang theo thiết bị di động của mình.

3.1.2. Các thư viện được sử dụng

Một số thư viện quan trọng được sử dụng trong suốt quá trình huấn luyện và thử nghiệm mô hình:

- **Thư viện yfinance:** Thư viện yfinance được sử dụng làm công cụ trích xuất dữ liệu chính cho hệ thống. Thông qua định danh GC=F, thư viện cho phép truy vấn trực tiếp vào cơ sở dữ liệu của Yahoo Finance để lấy thông tin về cặp tỷ giá XAU/USD. Điểm mạnh của thư viện này là khả năng cung cấp dữ liệu dưới định dạng Pandas DataFrame, giúp tối ưu hóa quá trình tiền xử lý và tích hợp trực tiếp vào thuật toán tối ưu hóa bầy đàn (PSO) mà không cần qua các bước chuyển đổi trung gian phức tạp.
- **Thư viện Pandas:** Thư viện Pandas đóng vai trò trung tâm trong giai đoạn quản lý và tiền xử lý dữ liệu chuỗi thời gian (time-series). Sau khi tiếp nhận dữ liệu từ yfinance, Pandas được sử dụng để chuẩn hóa cấu trúc dữ liệu, xử lý các giá trị khuyết thiếu và thiết lập chỉ mục thời gian cho mã vàng GC=F. Với các công cụ mạnh mẽ như Rolling Window, thư viện này giúp tính toán nhanh chóng các chỉ số kỹ thuật hỗ trợ, đồng thời tạo điều kiện thuận lợi cho việc phân tách tập dữ liệu thành các phần huấn luyện (training) và kiểm chứng (testing) một cách khoa học.
- **Thư viện NumPy:** Thư viện NumPy được ứng dụng làm nền tảng tính toán hiệu năng cao cho việc triển khai thuật toán tối ưu hóa bầy đàn (PSO). Bằng cách sử dụng cấu trúc mảng đa chiều (N-dimensional array), NumPy cho phép thực hiện các phép toán vector hóa trên toàn bộ bầy đàn, giúp cập nhật vị trí và vận tốc của các hạt trong không gian tìm kiếm với tốc độ tối ưu. Ngoài ra, các hàm toán học tích hợp của thư viện này còn hỗ trợ tính toán chính xác hàm thích nghi (fitness function) và các chỉ số sai số, đảm bảo hiệu suất tính toán cho mô hình dự báo trong môi trường Google Colab.

3.2. Hệ thống dữ liệu thực nghiệm

3.2.1. Nguồn gốc và đặc điểm dữ liệu

Tại chương này, chúng tôi sử dụng dữ liệu lịch sử giao dịch vàng thế giới thu thập trực tiếp từ cơ sở dữ liệu Yahoo Finance thông qua API của thư viện yfinance. Đây là bộ dữ liệu uy tín, cung cấp thông số giá vàng thế giới với độ trễ thấp.

Chúng tôi sử dụng dữ liệu từ 01-01-2015 đến nay, phục vụ cho quá trình huấn luyện mô hình dự báo. Dữ liệu được cập nhật theo khung thời gian (1 ngày) để kiểm chứng tính thực tế của mô hình.

Đối tượng thực nghiệm là mã giao dịch GC=F (một mã chuẩn trên Yahoo Finance) và cặp tỷ giá quy đổi XAU/USD giúp mô hình bám sát diễn biến thị trường ngoại hối và tài chính quốc tế.

Nghiên cứu không chỉ sử dụng riêng chuỗi giá vàng mà mở rộng thành bộ dữ liệu đa biến:


- Giá đóng cửa của vàng thế giới (Glod_Close).
- Chỉ số USD Index (DXY).
- Giá dầu thô (Oil).
- Chỉ số S&P 500 (SP500).
- Lợi suất trái phiếu Kho bạc Mỹ kỳ hạn 10 năm (Bond_Yield).
- Khối lượng giao dịch vàng (Gold_Volume).

Trong đó, Gold_Close là biến mục tiêu chính cần dự báo. Việc bổ sung các biến kinh tế - tài chính giúp mô hình khai thác được mối quan hệ tương quan giữa giá vàng và các yếu tố vĩ mô, từ đó nâng cao khả năng dự báo trong bối cảnh thị trường biến động mạnh.

Trước khi đưa vào mô hình, dữ liệu được sắp xếp theo thứ tự thời gian, xử lý giá trị thiếu bằng phương pháp nội suy tiến và chuẩn hóa về cùng miền giá trị bằng MinMaxScaler. Tập dữ liệu sau đó được chia theo tỷ lệ 80% cho huấn luyện và 20% cho kiểm tra theo đúng trình tự thời gian để bảo toàn tính chất chuỗi.

3.2.2. Phân tích tương quan

Trước khi huấn luyện, chúng tôi tiến hành phân tích ma trận tương quan để đánh giá mối quan hệ giữa các biến:



Hình 3.1. Ma trận tương quan giữa các biến tài chính và giá vàng

Dựa trên Hình 3.1, ta có các nhận xét quan trọng:

- **SP500 (0.85):** Đây là biến có mối tương quan thuận mạnh mẽ nhất với giá vàng. Hệ số 0.85 cho thấy trong giai đoạn dữ liệu này, chỉ số chứng khoán Mỹ và giá vàng thường xuyên biến động cùng chiều một cách rất chặt chẽ.
- **DXY (0.47):** Chỉ số đồng đô la Mỹ có mức tương quan thuận trung bình. Điều này khá thú vị vì thông thường vàng và USD hay có xu

hướng ngược chiều, nhưng trong tập dữ liệu cụ thể này, chúng lại có sự liên kết dương đáng kể.

- **Oil (0.06) và Gold_Volume (0.01):** Cả giá dầu và khối lượng giao dịch vàng đều có hệ số tương quan xấp xỉ bằng 0. Điều này cho thấy hai yếu tố này hầu như không có tác động tuyến tính hoặc ảnh hưởng rất ít đến xu hướng giá vàng trong phạm vi nghiên cứu này.
- **Bond_Yield (-0.02):** Lợi suất trái phiếu có mối tương quan nghịch cực kỳ thấp, cho thấy sự thay đổi của lợi suất trái phiếu không phản ánh rõ rệt lên sự tăng giảm của giá vàng trong tập dữ liệu này.

3.3. Thiết kế thực nghiệm

Quá trình thực nghiệm được thiết kế theo quy trình chuẩn của một bài toán học sâu dự báo chuỗi thời gian, kết hợp với thuật toán tối ưu hóa bầy đàn để tìm kiếm cấu hình mô hình tốt nhất.

3.3.1. Thu thập và tiền xử lý

Dữ liệu được trích xuất từ Yahoo Finance với khung thời gian từ 01/01/2015 đến nay. Để đảm bảo mô hình có cái nhìn toàn diện về thị trường, chúng tôi thiết lập một bộ đặc trưng (features) bao gồm các chỉ số tài chính có độ tương quan cao.

- **Xử lý giá trị khuyết thiếu:** Sử dụng phương pháp nội suy tuyến ('ffill') để lấp đầy các khoảng trống dữ liệu (do các thị trường có ngày nghỉ lễ khác nhau), đảm bảo tính liên tục của chuỗi thời gian.
- **Chuẩn hóa dữ liệu:** Vì các biến có đơn vị khác nhau (ví dụ: giá vàng > 2000 USD, lợi suất trái phiếu < 5%), chúng tôi áp dụng kỹ thuật MinMaxScaler để đưa toàn bộ dữ liệu về miền giá trị [0, 1]. Điều này giúp thuật toán Gradient Descent của LSTM hội tụ nhanh hơn và tránh việc các biến có giá trị lớn lấn át các biến khác.

3.3.2. Cấu trúc bộ dữ liệu đầu vào (Windowing)

Để mô hình LSTM có thể học được tính phụ thuộc thời gian, dữ liệu được chuyển đổi từ dạng bảng phẳng sang dạng cửa sổ trượt (sliding window).

- **Tham số Look-back:** Số lượng ngày trong quá khứ được dùng để dự báo giá ngày kế tiếp. Qua thực nghiệm PSO, giá trị này được tối ưu tại 91 ngày.
- **Cấu trúc Input (X):** Một mảng 3 chiều có dạng (samples, time_steps, features).
- **Cấu trúc Output (y):** Giá đóng cửa của vàng (Gold_Close) tại thời điểm $t+1$.

...

```
def create_multivariate_dataset(data, look_back=60):
```

```
    X, y = [], []
```

```
    for i in range(len(data) - look_back):
```

```
        X.append(data[i:(i + look_back), :])
```

```
        y.append(data[i + look_back, 0])
```

```
    return np.array(X), np.array(y)
```

...

3.3.3. Phân chia tập dữ liệu

Tập dữ liệu sau khi xử lý được chia theo trình tự thời gian (Time-series Split) để tránh hiện tượng "nhìn trước tương lai" (look-ahead bias):

- **Tập huấn luyện (Training Set - 80%):** Dùng để mô hình học các quy luật biến động và thuật toán PSO tìm kiếm siêu tham số.
- **Tập kiểm tra (Testing Set - 20%):** Dùng để đánh giá khách quan hiệu năng của mô hình trên dữ liệu hoàn toàn mới.

3.3.4. Tối ưu hóa siêu tham số bằng PSO

Điểm cốt lõi trong kiến trúc đề xuất là việc tích hợp thuật toán Tối ưu hóa bầy đàn (Particle Swarm Optimization - PSO) nhằm tự động hóa quy trình tìm kiếm siêu tham số, thay thế cho phương pháp thử sai (trial-and-error) thủ công vốn tốn kém thời gian và không đảm bảo tính hội tụ.

Trong nghiên cứu này, PSO điều phối một quần thể gồm các hạt "bay" trong không gian tìm kiếm đa chiều. Mỗi hạt đại diện cho một bộ cấu hình tiềm năng của mô hình LSTM. Không gian tìm kiếm được định nghĩa qua 6 tham số trọng yếu như sau:

Bảng 3.1. Bảng thiết lập cấu hình không gian tìm kiếm cho PSO

Tham số tối ưu hóa	Miền giá trị tìm kiếm	Ý nghĩa
Look-back	[15, 120]	Độ dài chuỗi dữ liệu đầu vào
Hidden Units	[50, 220]	Khả năng ghi nhớ của lớp LSTM
Learning Rate	[0.0001, 0.01]	Tốc độ cập nhật trọng số
Batch Size	[16, 128]	Số mẫu dữ liệu mỗi lần cập nhật
LSTM Layers	[1, 3]	Độ sâu của kiến trúc mạng

Dropout	[0.0, 0.3]	Khả năng chống quá khớp (Overfitting)
----------------	------------	--

Hàm thích nghi (Fitness Function): Được thiết lập dựa trên sự kết hợp giữa RMSE và MAPE trên tập validation. Mục tiêu của PSO là tìm vị trí hạt sao cho hàm thích nghi đạt giá trị nhỏ nhất.

3.4. Kết quả thực nghiệm

Trường hợp 1. Mô phỏng và tối ưu mô hình PSO-LSTM – Tối ưu hóa quần thể diện rộng (Bộ 1)


Trong trường hợp này, thuật toán Bầy đàn (PSO) được sử dụng để tìm bộ siêu tham số tối ưu cho mô hình LSTM đa biến. Không gian tìm kiếm của PSO bao gồm 6 tham số: look_back, số nút ẩn, tốc độ học, kích thước batch, số lớp LSTM và tỷ lệ dropout. Các tham số này được định nghĩa với các giới hạn min/max phù hợp để đảm bảo tính hợp lệ và hiệu quả của mô hình.

Quá trình tối ưu sử dụng 30 hạt, 20 vòng lặp, với các tham số điều khiển $c1 = 2,0$; $c2 = 2,0$; $w = 0,4$. Hàm mục tiêu của PSO không chỉ xét RMSE mà còn kết hợp thêm MAPE như một hình phạt bổ sung. Kết quả sau khi chạy PSO thu được bộ siêu tham số tốt nhất bao gồm:

- Look-back = 110; Hidden units = 218; Learning rate = 0.00729; Batch size = 52; Số lớp LSTM = 1; Dropout rate = 0.26.

Kết quả thực nghiệm cuối cùng được ghi nhận là:

- MAE = 286.41 USD; RMSE = 307.65 USD; MAPE = 5.79%; $R^2 = -5.242$; Directional Accuracy = 53.19%.



Hình 3.2. Kết quả dự báo của mô hình PSO-LSTM Bộ 1 trên tập Test Benchmark

Mô hình PSO-LSTM không bám sát đường giá thực tế một cách tốt. Độ chính xác tổng thể chỉ ở mức trung bình-thấp. Đường dự đoán (đỏ) có xu hướng phẳng hơn, ít biến động mạnh so với đường thực tế (xanh), dẫn đến việc bỏ lỡ nhiều biến động lớn của giá vàng.

Trường hợp 2. Mô phỏng và tối ưu mô hình PSO-LSTM – Tối ưu hóa hội tụ nhanh (Bộ 2)


Trong trường hợp này, thuật toán Bầy đàn (PSO) tập trung vào việc tìm kiếm các cấu hình mạng đơn giản nhưng nhạy bén. Không gian tìm kiếm vẫn duy trì 6 tham số cốt lõi nhằm đảm bảo tính khách quan giữa các lần thử nghiệm.

Quá trình tối ưu sử dụng 10 hạt, 10 vòng lặp, với các tham số điều khiển $c1 = 2,0$; $c2 = 2,0$; $w = 0,9$. Hàm mục tiêu ưu tiên các nghiệm vừa có sai số tuyệt đối thấp vừa có sai số tương đối ổn định. Kết quả sau khi chạy PSO thu được bộ siêu tham số tốt nhất bao gồm:

- Look-back = 18; Hidden units = 102; Learning rate = 0.00324; Batch size = 18; Số lớp LSTM = 1; Dropout rate = 0.16.

Kết quả thực nghiệm cuối cùng được ghi nhận là:

- $MAE = 74.21$ USD; $RMSE = 114.36$ USD; $MAPE = 2.13\%$; $R^2 = 0.9823$; Directional Accuracy = 53.83%.



Hình 3.3. Kết quả dự báo của mô hình PSO-LSTM Bộ 2 trên tập Test Benchmark

Đường dự đoán (màu đỏ) bám sát rất tốt đường giá thực tế (màu xanh) trên hầu hết tập test (khoảng 550 ngày). Mô hình nắm bắt khá chính xác cả xu hướng dài hạn (tăng dần) lẫn các biến động ngắn hạn.

Trường hợp 3. Mô phỏng và tối ưu mô hình PSO-LSTM – Cấu hình cân bằng (Bộ 3)

Trong trường hợp này, thuật toán Bầy đàn (PSO) được sử dụng để tìm điểm cân bằng giữa hiệu suất dự báo và chi phí tính toán trong không gian 6 chiều. Các tham số được định nghĩa với giới hạn tìm kiếm nghiêm ngặt nhằm đảm bảo mô hình không rơi vào tình trạng quá khớp khi xử lý các chuỗi dữ liệu dài.

Quá trình tối ưu sử dụng 12 hạt, 10 vòng lặp, với các tham số điều khiển $c1 = 2,0$; $c2 = 2,0$; $w = 0,78$. Hàm mục tiêu được thiết lập dựa trên sự kết hợp giữa RMSE và MAPE, đóng vai trò như một hàm phạt để ưu tiên các bộ tham số có độ lệch tuyệt đối thấp. Kết quả sau khi chạy PSO thu được bộ siêu tham số tốt nhất của mô hình bao gồm:


- Look-back = 104; Hidden units = 151; Learning rate = 0.00425; Batch size = 23; Số lớp LSTM = 1; Dropout rate = 0.16.

Từ bộ tham số này, mô hình PSO-LSTM được huấn luyện và đánh giá trên tập kiểm tra. Các chỉ số đánh giá cho thấy khả năng phản ánh tương đối ổn định về giá trị, tuy nhiên khả năng nhận diện xu hướng có sự sụt giảm nhẹ so với các trường hợp trước đó.

Kết quả thực nghiệm cuối cùng được ghi nhận là:

- $MAE = 141.69$ USD; $RMSE = 193.97$ USD; $MAPE = 3.83\%$; $R^2 = 0.9496$; $Directional Accuracy = 51.91\%$.

So với các cấu hình khác, Trường hợp 3 cho thấy một kiến trúc mạng với cửa sổ Look-back khá dài (104 ngày) nhưng vẫn duy trì được chỉ số R^2 ở mức cao (xấp xỉ 0.95), khẳng định độ tin cậy của mô hình trong việc giải thích sự biến động của dữ liệu thực tế. Tuy nhiên, sai số MAPE đạt 3.83% cho thấy sự tối ưu hóa tại bộ tham số này chưa đạt tới mức lý tưởng như cấu hình tại Trường hợp 2 hay Trường hợp 4.



Hình 3.4. Kết quả dự báo của mô hình PSO-LSTM Bộ 3 trên tập Test Benchmark

Mô hình cho hiệu suất tốt, nhưng thấp hơn rõ rệt so với trường hợp 2 (biểu đồ trước đó). Đường dự đoán (màu đỏ) vẫn bám theo xu hướng tăng dài hạn của giá vàng, nhưng sai số lớn hơn, đặc biệt ở nửa sau biểu đồ. Đường đỏ có xu hướng thấp hơn đường xanh ở hầu hết các giai đoạn quan trọng, cho thấy mô hình hơi thiên về dự báo bảo thủ (underestimate).

Trường hợp 4. Mô phỏng và tối ưu mô hình PSO-LSTM – Cấu hình tinh chỉnh đa mục tiêu (Bộ 4)

Trong trường hợp này, thuật toán Bầy đàn (PSO) được cấu hình nhằm tìm kiếm một điểm tối ưu có khả năng cân bằng giữa sai số tương đối (MAPE) và độ chính xác về mặt xu hướng (Directional Accuracy). Điểm khác biệt lớn nhất ở bộ này là việc tối ưu hóa trong một không gian tham số tập trung vào tính ổn định toàn cục của mô hình.


Quá trình tối ưu sử dụng quần thể 12 hạt, thực hiện qua 10 vòng lặp, với các tham số điều khiển $c1 = 2,0$; $c2 = 2,0$; $w = 0,9$. Việc duy trì hệ số quán tính cao giúp thuật toán không bị mắc kẹt tại các cực trị địa phương và đạt được giá trị Best cost thấp nhất trong tất cả các bộ thực nghiệm (78.4). Kết quả sau khi chạy PSO đã xác định được bộ siêu tham số tối ưu bao gồm:

- Look-back: 68; Hidden units: 210; Learning rate: 0.00537; Batch size: 24; Số lớp LSTM: 1; Dropout rate: 0.14

Từ bộ tham số tối ưu này, mô hình PSO-LSTM đã được huấn luyện và đánh giá trên tập kiểm tra. Các chỉ số hiệu năng ghi nhận được như sau:

- MAE: 103.77 USD; RMSE: 143.03 USD; MAPE: 2.16%; R^2 : 0.6713; Directional Accuracy: 55.32%

Phân tích kết quả: Trường hợp 4 ghi nhận chỉ số Directional Accuracy đạt 55.32%, đây là giá trị cao nhất trong toàn bộ 4 trường hợp thực nghiệm vừa nêu. Điều này cho thấy cấu hình tại nêu có khả năng đặc biệt vượt trội trong việc dự báo đúng hướng tăng/giảm của giá vàng, một yếu tố then chốt trong các quyết định đầu tư tài chính. Mặc dù sai số MAPE (2.16%) cao hơn một chút so với Bộ 4 (2.13%), nhưng sự chênh lệch này là không đáng kể so với lợi thế về khả năng bắt kịp xu hướng (Trend-following) mà mô hình này mang lại. Với số đơn vị ẩn lớn (210 units) và cửa sổ quan sát vừa phải (68 ngày), mô hình đã đạt được độ nhạy bén cao với các biến động ngắn hạn của thị trường.




Hình 3.5. Kết quả dự báo của mô hình PSO-LSTM Bộ 4 trên tập Test Benchmark

Mô hình cho hiệu suất tốt, nhưng thấp hơn một bậc so với trường hợp 2 (biểu đồ bám sát nhất). Đường dự đoán (màu đỏ) vẫn theo sát xu hướng tăng dài hạn, tuy nhiên thường nằm thấp hơn đường giá thực tế (màu xanh), đặc biệt ở giai đoạn tăng mạnh cuối. Sai số tổng thể ở mức chấp nhận được, nhưng rõ ràng có hiện tượng underestimate (dự báo thấp hơn thực tế) ở nửa sau biểu đồ.

Trường hợp 5. So sánh mô hình PSO-LSTM (Bộ 4) với mô hình LSTM Baseline

Để đánh giá khách quan giá trị của thuật toán PSO trong việc tối ưu hóa siêu tham số, nghiên cứu tiến hành xây dựng một mô hình đối chứng LSTM Baseline với cấu hình cố định dựa trên các thiết lập tiêu chuẩn trong dự báo chuỗi thời gian. Mô hình Baseline sử dụng các tham số: Look-back = 60; Hidden units = 128; LSTM Layers = 2; Learning rate = 0.001; Dropout = 0.2; Batch size = 32.

Hai mô hình được đánh giá trên cùng một tập dữ liệu kiểm tra với hệ thống chỉ số thống kê toàn diện. Kết quả so sánh được tổng hợp chi tiết nhằm đối chiếu sự khác biệt giữa việc thiết lập thủ công và tối ưu hóa tự động.



Hình 3.6. Biểu đồ so sánh PSO-LSTM (Bộ 4) và LSTM Baseline trên tập Test Benchmark

Bảng 3.2. Bảng tổng hợp các chỉ số đánh giá hiệu năng

Chỉ số	PSO-LSTM (Bộ 4)	LSTM Baseline
MAE	103.77	187.75
RMSE	143.03	204.78
MAPE	2.16%	3.80%
R^2	0.6713	0.3261
Directional Accuracy	55.32%	42.55%

3.5. Đánh giá kết quả thực nghiệm

Dựa trên kết quả từ 4 kịch bản tối ưu hóa bằng PSO (Trường hợp 1 đến 4) và mô hình đối chứng (Trường hợp 5), nghiên cứu đưa ra các đánh giá tổng hợp về hiệu năng và tính khả thi của mô hình PSO-LSTM như sau:

Thứ nhất, vai trò quyết định của việc tối ưu hóa siêu tham số tự động. Kết quả thực nghiệm cho thấy sự chênh lệch rõ rệt giữa việc thiết lập thủ công và tối ưu hóa bằng bầy đàn. Mô hình PSO-LSTM (Bộ 4) đạt mức cải thiện sai số MAPE vượt trội, giảm từ 3,80% (Baseline) xuống còn 2,16%. Điều này khẳng định rằng trong không

gian tham số phức tạp của mạng LSTM, việc sử dụng PSO giúp tìm ra những "điểm ngọt" (sweet spots) về cấu hình (như sự kết hợp giữa Look-back 68 và Hidden units 210 tại Bộ 4) mà phương pháp thử sai thủ công khó có thể đạt tới.

Thứ hai, khả năng nhận diện xu hướng và ý nghĩa trong dự báo tài chính. Chỉ số Directional Accuracy (DA) ghi nhận mức cao nhất tại Trường hợp 4 với 55,32%, so với mức dưới trung bình (42,55%) của Baseline. Trong bài toán dự báo giá vàng, DA mang ý nghĩa sống còn hơn cả các sai số trị giá (MAE, RMSE), vì nó phản ánh khả năng xác định đúng chiều biến động tăng/giảm. Việc mô hình bám sát các nhịp biến động dài hạn, dù đôi khi có hiện tượng dự báo thấp hơn thực tế (underestimate) ở các giai đoạn tăng trưởng nóng, vẫn cung cấp một công cụ hỗ trợ quyết định đầu tư có độ tin cậy cao.

Thứ ba, sự tương quan giữa cấu trúc mạng và đặc tính dữ liệu đa biến. Việc bổ sung các biến thị trường và kinh tế vĩ mô đã giúp mô hình khai thác được các tín hiệu hỗ trợ từ bên ngoài thay vì chỉ phụ thuộc vào chuỗi giá quá khứ. Các kết quả thực nghiệm cho thấy khi PSO tìm ra các cửa sổ Look-back phù hợp (từ 18 đến 91 ngày), mô hình đạt được sự cân bằng giữa việc ghi nhớ dài hạn và phản xạ nhanh với các biến động ngắn hạn. Chỉ số R^2 cải thiện đáng kể từ 0,32 (Baseline) lên 0,67–0,98 tùy trường hợp, minh chứng cho khả năng giải thích biến động dữ liệu mạnh mẽ của kiến trúc đề xuất.

Tuy nhiên, nghiên cứu vẫn ghi nhận một số hạn chế cần lưu ý:

1. Hiện tượng dự báo bảo thủ: Tại các kịch bản cho hiệu suất tốt (Bộ 3, Bộ 4), đường dự báo thường nằm thấp hơn giá thực tế ở các giai đoạn tăng mạnh. Điều này cho thấy mô hình vẫn gặp thách thức trong việc phản ứng tức thời với các cú sốc thị trường cực đại hoặc các biến động "thiên nga đen".
2. Độ bao phủ của đặc trưng: Tập dữ liệu hiện tại dù đã đa biến nhưng vẫn chưa định lượng hóa được các yếu tố tâm lý thị trường (Sentiment) hay các biến cố địa chính trị đột xuất, vốn là những tác nhân gây nhiễu mạnh cho giá vàng.

Nhìn chung, kết quả thực nghiệm khẳng định việc kết hợp PSO với LSTM không chỉ là một hướng tiếp cận khả thi mà còn mang lại hiệu quả thực tiễn cao. Mô hình đã chứng minh được khả năng tối ưu hóa tự động đề thích nghi với dữ liệu tài chính có độ nhiễu cao, cung cấp một phương pháp luận tin cậy cho bài toán dự báo giá vàng trong ngắn và trung hạn.

3.6. Tóm tắt chương 3

Chương 3 đã tập trung trình bày chi tiết về môi trường thực nghiệm và quy trình triển khai mô hình dự báo giá vàng đa biến. Các nội dung trọng tâm bao gồm thiết lập hệ thống trên nền tảng Google Colab, khai thác dữ liệu kinh tế vĩ mô từ Yahoo Finance và quy trình tối ưu hóa siêu tham số bằng thuật toán PSO.

Kết quả thực nghiệm cho thấy phương pháp PSO-LSTM đề xuất mang lại sự cải thiện rõ rệt về độ chính xác và khả năng hội tụ so với mô hình LSTM truyền thống. Việc sử dụng các chỉ số sai số như MAE, RMSE và MAPE làm thước đo đánh giá chính giúp khẳng định tính hiệu quả của mô hình trong việc bám sát diễn biến thị trường thực tế. Những kết quả đạt được trong chương này là cơ sở quan trọng để tiến hành phân tích sâu hơn về khả năng ứng dụng của thuật toán trong các bài toán dự báo tài chính phức tạp.

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

Kết luận

Trong nghiên cứu này, chúng tôi đã trình bày một cách hệ thống các phương pháp tiếp cận và đóng góp quan trọng trong việc giải quyết bài toán dự đoán giá vàng theo thời gian thực. Thông qua quá trình nghiên cứu, chúng tôi đã thiết kế và triển khai thành công mô hình dự báo dựa trên sự kết hợp giữa các kiến trúc học máy hiện đại và thuật toán tối ưu hóa bầy đàn (PSO). Việc ứng dụng PSO đã chứng minh được hiệu quả vượt trội trong việc tự động tìm kiếm và tinh chỉnh bộ tham số tối ưu, giúp mô hình vượt qua những hạn chế về hội tụ cục bộ mà các phương pháp truyền thống thường gặp phải, từ đó nâng cao độ chính xác cho các kết quả dự báo.

Bên cạnh khía cạnh thuật toán, nghiên cứu cũng đã xây dựng được một quy trình xử lý dữ liệu thực tế linh hoạt, từ khâu thu thập thông tin tài chính trực tuyến đến việc phân tích ma trận tương quan giữa giá vàng và các chỉ số kinh tế vĩ mô. Kết quả thực nghiệm cho thấy mô hình đề xuất không chỉ đạt được các chỉ số sai số thấp như RMSE và MAE mà còn thể hiện khả năng thích ứng tốt với những biến động phức tạp của thị trường vàng trong ngắn hạn. Điều này khẳng định rằng việc kết hợp thuật toán metaheuristic vào các mô hình học máy là một hướng đi đúng đắn và có tiềm năng ứng dụng cao.

Tổng kết lại, những kết quả đạt được trong nghiên cứu này đã cung cấp một công cụ hỗ trợ ra quyết định có cơ sở khoa học, góp phần giải quyết bài toán dự báo tài chính trong điều kiện thị trường thay đổi liên tục. Những đóng góp về mặt lý thuyết và thực nghiệm trong luận văn không chỉ dừng lại ở việc tối ưu hóa một mô hình cụ thể, mà còn tạo tiền đề vững chắc cho các nghiên cứu chuyên sâu hơn về ứng dụng trí tuệ nhân tạo trong lĩnh vực phân tích thị trường tài chính và quản lý rủi ro đầu tư.

Hướng phát triển

Mặc dù đã đạt được những kết quả khả quan ban đầu, nghiên cứu vẫn còn những dư địa có thể mở rộng nhằm tăng cường tính thực tiễn và độ tin cậy của mô hình dự báo. Trong các công trình tiếp theo, chúng tôi dự kiến sẽ nghiên cứu tích hợp

thêm các thuật toán metaheuristics khác hoặc phát triển các biến thể lai (Hybrid PSO) để so sánh và tìm ra giải pháp tối ưu hơn, đặc biệt là trong việc xử lý các tập dữ liệu tài chính có số chiều lớn và độ nhiễu cao.

Bên cạnh đó, việc đa dạng hóa nguồn dữ liệu đầu vào cũng là một hướng đi quan trọng. Chúng tôi sẽ hướng tới việc tích hợp thêm các kỹ thuật phân tích tâm lý thị trường (Sentiment Analysis) từ các nguồn tin tức kinh tế và mạng xã hội, kết hợp cùng dữ liệu lịch sử để phản ánh đầy đủ hơn bức tranh biến động giá vàng trong kỷ nguyên thông tin số. Đặc biệt, nghiên cứu có thể được phát triển thêm bằng cách huấn luyện trên các bộ dữ liệu giả lập được tạo bởi trí tuệ nhân tạo, đồng thời bổ sung các hệ tri thức chuyên gia hoặc công cụ theo dõi tin tức thực tế để nâng cao khả năng phản ứng của mô hình trước các sự kiện thiên nga đen.

Về mặt ứng dụng, mô hình có thể được chuẩn hóa để xây dựng thành một hệ thống cảnh báo sớm hoặc ứng dụng di động trực quan, hỗ trợ người dùng đưa ra quyết định đầu tư dựa trên các kịch bản dự báo đa bước (Multi-step forecasting) với độ trễ thấp nhất. Cuối cùng, để khẳng định tính tổng quát của khung thuật toán đã đề xuất, chúng tôi sẽ thực hiện các thử nghiệm mở rộng trên các loại tài sản tài chính khác như thị trường chứng khoán hoặc tiền mã hóa, từ đó đánh giá khả năng thích ứng của mô hình trong các môi trường đầu tư đa dạng và biến động.

DANH MỤC TÀI LIỆU THAM KHẢO

- [1] R. J. Hyndman and G. Athanasopoulos, *Forecasting: Principles and Practice*, 3rd ed. Melbourne, Australia: OTexts, 2021. [Online]. Available: <https://otexts.com/fpp3/>
- [2] I. E. Livieris, E. Pintelas, and P. Pintelas, "A CNN-LSTM model for gold price time-series forecasting", *Neural Computing and Applications*, vol. 32, no. 23, pp. 17351-17360, 2020. doi: 10.1007/s00521-020-04862-x.
- [3] G. E. P. Box, G. M. Jenkins, G. C. Reinsel, and G. M. Ljung, *Time Series Analysis: Forecasting and Control*, 5th ed. Hoboken, NJ, USA: Wiley, 2015.
- [4] Jing, Z., et al. (2026). "Gold Price Prediction Based on LSTM-Attention Combined Model", ResearchGate.
- [5] P. Anh và T. T. T. Dương, "Dự báo giá vàng nhìn từ mô hình hồi quy tuyến tính và mô hình học máy", *Tạp chí Kinh tế và Dự báo*, 2023.
- [6] N. T. H. Thảo et al., "Áp dụng một vài phương pháp máy học vào bài toán dự báo theo chuỗi thời gian", *Tạp chí Khoa học ĐHSP TP.HCM*, tập 19, số 12, 2022.
- [7] A. B. Nagata et al., "Predicting Gold Price Movement Using Long Short-Term Memory Model", *Journal of Applied Intelligent System*, tập 9, số 1, 2024.
- [8] X. Zeng et al., "Enhancing stock index prediction: A hybrid LSTM-PSO model for improved forecasting accuracy", *PLoS ONE*, tập 20, số 1, 2025.
- [9] M. Mousapour Mamoudan et al., "Hybrid neural network-based metaheuristics for prediction of financial markets: a case study on global gold market", *Journal of Computational Design and Engineering*, tập 10, số 3, 2023.
- [10] H. Kazak et al., "Metaheuristic-optimized ANFIS and ANN models for stock price forecasting", *Discover Artificial Intelligence*, tập 5, số 272, 2025.
- [11] Z. Wang, "The Effectiveness of Forecasting Gold Prices Using ARIMA Models", *Advances in Economics Management and Political Sciences*, 2025.
- [12] B. Xie, "Gold Price Forecast: A Summary of the Integration of Economic Factors and Calculation Methods", *SciTePress*, 2025.

- [13] R. Zhang, "Gold Price Relative Return Prediction with Machine Learning Models", SciTePress, 2024.
- [14] R. Lesko, "Comparing Machine Learning and Traditional Statistical Methods for Gold Price Prediction", ResearchGate, 2025.
- [15] X.-S. Yang, "Engineering Optimization: An Introduction with Metaheuristic Applications", Hoboken, N.J: John Wiley, 2010.
- [16] M. Ahmad et al., "Comparative Analysis of Statistical and Machine Learning Models for Gold Price Prediction", Journal of Media Horizons, tập 6, số 4, 2025.
- [17] O. S. Alamu and M. K. Siam, 'Stock Price Prediction and Traditional Models: An Approach to Achieve Short-, Medium- and Long-Term Goals', JILSA, vol. 16, no. 04, 2024.
- [18] Shcherbakov, M. V., et al. (2013). "A Survey of Forecast Error Measures", World Applied Sciences Journal, vol. 24, no. 12.
- [19] Chai, T., & Draxler, R. R. (2014). "Root mean square error (RMSE) or mean absolute error (MAE)?– Arguments against avoiding RMSE in the literature", Geoscientific Model Development, vol. 7, no. 3.
- [20] Willmott, C. J., & Matsuura, K. (2005). "Advantages of the Mean Absolute Error (MAE) over the Root Mean Square Error (RMSE) in Assessing Average Model Performance", Climate Research, vol. 30, no. 1.
- [21] Gers, F. A., Schmidhuber, J., & Cummins, F. (2000). "Learning to Forget: Continual Prediction with LSTM", Neural Computation, vol. 12, no. 10, pp. 2451-2471.
- [22] Yang, X. S. (2010). "Nature-Inspired Metaheuristic Algorithms", 2nd Edition, Luniver Press.
- [23] World Gold Council, "Gold Price Data and Statistics," Gold.org, 2024. [Online]. Available: <https://www.gold.org/goldhub/data/gold-prices>

- [24] Yahoo Finance, "Gold Dec 24 (GC=F) Stock Price, News, Quote & History," 2024. [Online]. Available: <https://finance.yahoo.com/quote/GC=F/>
- [25] Google Research, "Colaboratory Frequently Asked Questions," 2026. [Online]. Available: <https://research.google.com/colaboratory/faq.html>
- [26] Google for Developers, "Colab | Your AI-driven, all-purpose coding partner," 2026. [Online]. Available: <https://developers.google.com/colab>
- [27] S. Hochreiter and J. Schmidhuber, "Long short-term memory", *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [28] F. A. Gers, J. Schmidhuber, and F. Cummins, "Learning to forget: Continual prediction with LSTM", *Neural Computation*, vol. 12, no. 10, pp. 2451–2471, 2000.
- [29] F. A. Gers, N. N. Schraudolph, and J. Schmidhuber, "Learning precise timing with LSTM recurrent networks", *Journal of Machine Learning Research*, vol. 3, pp. 115–143, 2002.
- [30] A. Graves and J. Schmidhuber, "Framewise phoneme classification with bidirectional LSTM and other neural network architectures", *Neural Networks*, vol. 18, no. 5-6, pp. 602–610, 2005.
- [31] K. Greff, R. K. Srivastava, J. Koutník, B. R. Steunebrink, and J. Schmidhuber, "LSTM: A search space odyssey", *IEEE Transactions on Neural Networks and Learning Systems*, vol. 28, no. 10, pp. 2222–2232, 2017.
- [32] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio, "Learning phrase representations using RNN encoder–decoder for statistical machine translation," in *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, Oct. 2014, pp. 1724–1734

